

Master Automatique et Systèmes Électriques
Parcours SMaRT

**Fusion multimodale adaptative
pour véhicules autonomes**

*Fusion sélective multicapteurs pour la perception robuste
en conduite autonome*

Rapport de stage de fin d'études

Stage effectué au sein d'**Audensiel Innovation**

Boulogne-Billancourt

Auteur

Touwendé OUEDRAOGO

Encadrante entreprise

Dr Amira Mimouna

Tuteur universitaire

Marie Helene Bekaert

Année universitaire 2025–2026

Soutenance du 3 septembre 2026

Résumé

Ce rapport présente **PercepFlow**, une architecture de fusion sélective multicapteurs pour la perception en conduite autonome. Le système exploite les données radar, LiDAR et caméra du jeu de données RADIATE afin de détecter les usagers de la route dans des conditions de conduite variées, y compris dans des environnements dégradés tels que la pluie, le brouillard, la neige et l'obscurité nocturne.

Deux stratégies de sélection ont été étudiées successivement. Une première approche fondée sur des règles expertes et sur le contexte météorologique prédit, le *Knowledge Based Gating*, a d'abord été développée. Les limites d'une sélection à règles fixées *a priori* ont ensuite motivé la conception de PercepFlow, dont le mécanisme d'*Attention Gating* apprend à sélectionner les branches directement à partir des caractéristiques extraites par les capteurs.

L'évaluation finale de PercepFlow est réalisée sur environ 40 % des 60 séquences totales de RADIATE. Elle montre une mAP de 36,02 % et un score F1 de 60,3 %. Les performances sont particulièrement élevées sur les classes véhicules (mAP 52,96 %), tandis que les classes rares restent plus difficiles à détecter (mAP 19,09 %), en cohérence avec le déséquilibre des annotations.

Table des matières

Liste des figures	5
Liste des tableaux	6
1 Introduction	7
1.1 Contexte sociétal et industriel	7
1.2 La perception comme verrou technique	7
1.3 Fusion multicapteurs et limites de la fusion systématique	8
1.4 Contribution de ce travail	8
1.5 Organisation du rapport	9
2 Cahier des charges	10
2.1 Le groupe Audensiel	10
2.1.1 Identité et positionnement	10
2.1.2 Domaines d'expertise	11
2.1.3 Trajectoire et chiffres clés	12
2.1.4 Implantations	13
2.2 Audensiel Innovation, structure d'accueil	13
2.3 Le projet DriveSense	13
2.3.1 Objectifs et périmètre	14
2.3.2 Travaux antérieurs et continuité	14
2.4 Objectifs du stage	15
2.5 Contraintes et périmètre	16
2.6 Organisation et suivi des travaux	17
2.6.1 Encadrement	17
2.6.2 Démarche adoptée	17
2.6.3 Planification	18
3 État de l'art	19
3.1 Capteurs embarqués pour les systèmes de transport intelligents	19
3.2 Détection d'objets	21
3.3 Fusion de données pour la perception	22
3.4 Architectures de fusion dynamique	23
3.4.1 HydraFusion : formulation et architecture	23
3.4.2 Les quatre stratégies de gating	24
3.4.3 Résultats rapportés et enseignements	25
3.4.4 Autres approches de fusion dynamique	27
3.5 Robustesse aux dégradations : l'apport des travaux d'évaluation	28
3.6 Représentations en vue de dessus et projection de la caméra	29
3.7 Verrous identifiés et positionnement de la contribution	30

4	Jeu de données et capteurs utilisés	33
4.1	Présentation du jeu de données RADIATE	33
4.1.1	Volume et organisation	33
4.1.2	Dispositif d'acquisition	33
4.1.3	Comportement des modalités en conditions dégradées	34
4.1.4	Formats de données	35
4.1.5	Calibration et repère de référence	36
4.1.6	Structure des annotations	37
4.1.7	Distribution des classes annotées	37
4.2	Capteurs embarqués de la plateforme RADIATE	38
4.3	Synchronisation temporelle des capteurs par le SDK RADIATE	39
5	Problématique	42
6	Architecture PercepFlow	43
6.1	Évaluation préalable des détecteurs monomodaux	43
6.1.1	Détecteur radar	43
6.1.2	Détecteur caméra	44
6.1.3	Détecteur LiDAR BEV	45
6.1.4	Synthèse comparative	47
6.2	Intégration de la caméra en BEV : approches étudiées	47
6.2.1	Approche 1 : BEV stéréo par SGBM	47
6.2.2	Approche 2 : caméra frontale avec Faster R-CNN natif et fusion tardive	48
6.2.3	Approche 3 : IPM (Inverse Perspective Mapping)	48
6.2.4	Approche 4 : Lift, Splat, Shoot	48
6.3	Vue d'ensemble des deux architectures dynamiques	50
6.4	Première approche : Knowledge Based Gating	51
6.5	Architecture PercepFlow : Attention Gating	53
7	Protocole expérimental et entraînement	56
7.1	Moyens de calcul	56
7.2	Répartition des données	57
7.3	Entraînement de PercepFlow	57
7.3.1	Organisation en phases	57
7.3.2	Configuration d'entraînement	58
7.3.3	Fonctions de perte	59
7.3.4	Composition des lots	59
7.4	Détails d'implémentation de l'architecture	60
7.5	Entraînement de WeatherCNN	60
7.6	Métriques d'évaluation	61

8 Résultats et analyse	63
8.1 Performances globales de PercepFlow	63
8.2 Ablation sur le nombre de branches sélectionnées	64
8.3 Résultats par classe	65
8.4 Analyse des classes rares	65
8.5 Comportement du module d'Attention Gating	65
8.6 Expérimentations avec le Knowledge Based Gating et WeatherCNN	66
8.6.1 Résultats du classificateur WeatherCNN	66
8.6.2 Analyse qualitative des stratégies de gating	67
9 Interface de visualisation et de démonstration	70
9.1 Objectifs de l'interface	70
9.2 Architecture logicielle	71
9.3 Synchronisation et déroulement d'une inférence	71
9.4 Organisation de la page et parcours utilisateur	72
9.5 Technologies employées	75
9.6 Portée et limites	75
9.7 Perspectives d'évolution	76
10 Discussion	77
10.1 Ce que les résultats établissent	77
10.2 Limites	78
10.3 Portée des résultats	78
11 Conclusion et perspectives	80
A Capteurs de la plateforme RADIATE	81
B Dimensions des représentations dans PercepFlow	82
C Composition de l'ensemble de test	83

Table des figures

1	Siège du groupe Audensiel à Boulogne-Billancourt.	11
2	Implantations du groupe Audensiel.	13
3	Planification des travaux sur la durée du stage.	18
4	Architecture multi-branches de HydraFusion, d'après [17].	24
5	Disposition des capteurs sur le véhicule d'acquisition RADIATE.	34
6	Comportement des trois modalités selon la condition d'acquisition.	35
7	Distribution des objets annotés dans RADIATE, par classe et par scénario.	37
8	Durée des scénarios RADIATE et part annotée.	38
9	Synchronisation temporelle des capteurs par le SDK RADIATE.	41
10	Performances globales du détecteur radar sur l'ensemble monomodal.	44
11	Performances globales du détecteur caméra sur l'ensemble monomodal.	44
12	Performances du détecteur caméra selon la condition météorologique.	45
13	Performances globales du détecteur LiDAR BEV sur l'ensemble monomodal.	46
14	Performances du détecteur LiDAR BEV selon la condition météorologique.	46
15	Comparaison globale des trois détecteurs monomodaux.	47
16	Principe de l'étape <i>Lift</i>	49
17	Architecture générale de <i>Lift</i> , <i>Splat</i> , <i>Shoot</i>	49
18	Architecture du <i>Knowledge Based Gating</i>	52
19	Architecture générale de PercepFlow.	54
20	Performances globales de PercepFlow sur l'ensemble de test (seuil de score 0,60).	63
21	Impact du nombre de branches sélectionnées k sur les performances.	64
22	Précision moyenne par classe sur l'ensemble de test.	65
23	Fréquence de sélection des branches par le module d' <i>Attention Gating</i> , selon la condition météorologique.	66
24	Performances du classificateur WeatherCNN par classe météorologique.	66
25	Analyse qualitative du <i>Knowledge Based Gating</i>	67
26	Analyse qualitative de PercepFlow.	68
27	Architecture logicielle de l'interface PercepFlow.	71
28	Interface sur la séquence <code>fog_8_1</code> : la caméra seule ne détecte pas le véhicule visible à gauche, le LiDAR ne renvoie que quelques points, mais le radar l'identifie et la fusion le restitue correctement.	73
29	Interface sur la séquence <code>snow_1_0</code> : une détection radar qui ne se retrouve pas dans la sortie fusionnée projetée.	74

Liste des tableaux

1	Pôles d'expertise du groupe Audensiel.	12
2	Principales étapes du développement du groupe Audensiel.	12
3	Contributions antérieures du projet DriveSense dont ce travail hérite. .	14
4	Phases de déroulement du stage.	18
5	Caractéristiques des principaux capteurs de perception de l'environnement.	20
6	Niveaux de fusion multicapteurs et compromis associés.	22
7	Stratégies de <i>gating</i> proposées dans HydraFusion [17].	25
8	Performances de détection rapportées sur RADIATE [17].	26
9	Performances selon la stratégie de <i>gating</i> et le nombre k de branches activées [17].	26
10	Synthèse comparative des approches de fusion dynamique.	28
11	Caractéristiques des capteurs de la plateforme RADIATE [21].	34
12	Représentations disponibles dans RADIATE et usage dans ce travail. .	36
13	Capteurs de la plateforme RADIATE et représentation retenue.	39
14	Correspondance entre indice Python et fichier radar.	40
15	Triplet synchronisé pour <i>city_1_1</i>	40
16	Détecteurs monomodaux évalués.	43
17	Données de réentraînement du LiDAR BEV.	45
18	Approches d'intégration caméra en BEV.	49
19	Présentation des deux méthodes étudiées, dans leur ordre de développe- ment.	50
20	Les sept branches de détection, communes aux deux méthodes de sélection.	51
21	Règles du <i>Knowledge Based Gating</i>	52
22	Répartition des séquences RADIATE entre les trois ensembles.	57
23	Paramètres optimisés à chaque phase d'entraînement.	58
24	Hyperparamètres des phases d'entraînement.	58
25	Configuration du classificateur WeatherCNN.	61
26	Comparaison des deux stratégies de sélection sur l'ensemble de test. .	63
27	Organisation visuelle de l'interface.	72
28	Technologies mises en œuvre dans l'interface.	75
29	Capteurs de la plateforme RADIATE et représentation retenue.	81
30	Formes des tenseurs le long du pipeline PercepFlow.	82
31	Séquences RADIATE composant l'ensemble de test, par condition d'ac- quisition.	83

CHAPITRE 1

Introduction

1.1 Contexte sociétal et industriel

La conduite autonome constitue l'un des principaux axes de transformation du secteur automobile. Sa motivation première est la sécurité routière : les accidents de la route figurent parmi les premières causes de mortalité dans le monde, avec plus d'un million de décès chaque année, et la très grande majorité d'entre eux résulte d'une erreur humaine. En déléguant tout ou partie de la conduite à un système automatisé, on cherche à supprimer les défaillances liées à l'inattention, à la fatigue ou à une mauvaise appréciation d'une situation. S'y ajoutent des bénéfices attendus en matière de fluidité du trafic, de consommation énergétique et d'accessibilité de la mobilité.

Cette promesse reste toutefois conditionnée à la fiabilité de la perception. Plusieurs accidents impliquant des véhicules automatisés ont été directement rattachés à des défaillances de perception : objet non détecté, obstacle mal classé, ou situation mal interprétée. Ces cas rappellent que la chaîne de décision d'un véhicule autonome ne peut être plus fiable que la représentation de l'environnement sur laquelle elle s'appuie. La perception constitue donc le maillon critique de l'ensemble du système.

1.2 La perception comme verrou technique

La perception a pour fonction de construire, à chaque instant, une représentation exploitable de la scène routière. Concrètement, il s'agit de détecter et de localiser les usagers présents autour du véhicule, qu'il s'agisse de véhicules, de piétons, de cyclistes ou d'obstacles fixes, puis de leur attribuer une classe et une position dans un repère métrique utilisable par les modules de planification de trajectoire.

Cette tâche, déjà difficile en conditions favorables, se complique considérablement dans les conditions dégradées. La pluie, le brouillard, la neige, la faible luminosité nocturne ou les occultations partielles altèrent la qualité des observations et dégradent les performances des détecteurs. Or ces conditions ne sont pas des cas marginaux : elles correspondent à une part importante des situations de conduite réelles, et ce sont précisément celles où l'assistance apportée par un système automatisé serait la plus utile. Un système de perception qui ne fonctionnerait qu'en conditions claires n'aurait donc qu'un intérêt limité.

1.3 Fusion multicapteurs et limites de la fusion systématique

Aucun capteur ne couvre à lui seul l'ensemble des situations de conduite. La caméra fournit une information visuelle riche, indispensable à l'interprétation sémantique de la scène, mais elle dépend fortement des conditions d'éclairage et de la météo. Le radar conserve une bonne robustesse face à la pluie, au brouillard et à l'obscurité, au prix d'une résolution spatiale plus grossière. Le LiDAR restitue une géométrie précise de la scène, mais reste sensible aux phénomènes diffusants comme le brouillard ou la neige.

Cette complémentarité justifie le recours à la fusion multicapteurs, qui combine plusieurs modalités pour construire une représentation plus complète que celle qu'offrirait chacune isolément. Un constat traverse cependant la littérature récente : fusionner systématiquement toutes les modalités disponibles n'améliore pas nécessairement la performance [17, 7, 11]. Lorsqu'une source devient bruitée ou peu fiable, son intégration peut dégrader la détection finale plutôt que l'enrichir. Le problème n'est donc pas seulement de fusionner, mais de décider quoi fusionner, et quand.

C'est cette observation qui motive les architectures de *fusion adaptative*, capables de sélectionner dynamiquement les modalités ou les combinaisons de capteurs les plus pertinentes selon le contexte courant, plutôt que d'appliquer un schéma de combinaison figé.

1.4 Contribution de ce travail

Ce stage s'inscrit dans le projet de recherche DriveSense conduit par Audensiel Innovation [1], dont l'objectif est la conception d'un système de perception robuste aux conditions de conduite dégradées. Deux stratégies de sélection dynamique ont été étudiées successivement, toutes deux évaluées sur le jeu de données RADIATE [21], spécifiquement construit autour des conditions météorologiques difficiles.

La première, le *Knowledge Based Gating*, repose sur des règles expertes déclenchées par la condition météorologique prédite en ligne par un classifieur dédié. Interprétable et directement dérivée des domaines de validité mesurés pour chaque capteur, elle s'est révélée limitée par le caractère figé de ses règles et par sa dépendance à la caméra pour identifier le contexte.

Ce constat a motivé la conception de **PercepFlow**, nom donné dans ce travail à l'architecture de fusion sélective proposée. Son mécanisme d'*Attention Gating* apprend à attribuer un score à chacune des sept branches de détection à partir des seules caractéristiques extraites par le réseau, sans aucune règle météorologique explicite. Une contribution technique complémentaire porte sur l'intégration de la caméra : ses caractéristiques sont projetées en vue de dessus au moyen d'un module *Lift, Splat, Shoot* [19], ce qui permet de l'inclure comme candidat à part entière du processus de

sélection, là où les travaux antérieurs la traitaient en aval de la fusion.

1.5 Organisation du rapport

Le présent rapport s'organise en dix chapitres. Le chapitre 2 présente l'entreprise d'accueil, le projet DriveSense dans lequel s'inscrit le stage, et les objectifs qui lui ont été fixés. Le chapitre 3 dresse l'état de l'art de la perception multicapteurs, depuis les capteurs et les détecteurs d'objets jusqu'aux architectures de fusion dynamique, et positionne la contribution au regard des travaux existants. Le chapitre 4 décrit le jeu de données RADIATE et la chaîne de synchronisation temporelle des capteurs.

Le chapitre 5 formalise la problématique. Le chapitre 6 présente l'évaluation préalable des détecteurs monomodaux, la résolution du verrou géométrique posé par la caméra, puis les deux architectures de fusion sélective étudiées. Le chapitre 7 détaille le protocole expérimental et les procédures d'entraînement, et le chapitre 8 rassemble les résultats quantitatifs et qualitatifs. Les chapitres 10 et 11 en discutent la portée et les limites, et dégagent les perspectives.

CHAPITRE 2

Cahier des charges

Ce chapitre présente l'entreprise d'accueil, en allant du groupe jusqu'au service et au projet de recherche dans lequel le stage s'inscrit, puis expose les objectifs qui lui ont été fixés et l'organisation retenue pour les atteindre.

2.1 Le groupe Audensiel

2.1.1 Identité et positionnement

Audensiel est un groupe de conseil en technologies et en transformation numérique fondé en 2013 par Nicolas Pacault, qui en assure aujourd'hui la présidence. Son siège social est établi au 93 rue Nationale, à Boulogne-Billancourt, dans les Hauts-de-Seine.

Le groupe se définit comme un partenaire d'ingénierie et de conseil accompagnant ses clients sur l'ensemble du cycle de vie de leurs projets technologiques, depuis le cadrage stratégique jusqu'à la réalisation et à l'exploitation. Il intervient auprès de grands comptes issus de secteurs variés : banque et finance, assurance, défense, santé, transports et industrie, luxe et distribution, médias et services publics. Cette diversité sectorielle constitue un trait caractéristique du modèle : elle limite la dépendance à un marché unique et favorise la circulation des compétences entre domaines.

Audensiel est par ailleurs constituée en **entreprise à mission**, statut introduit en droit français par la loi Pacte de 2019, qui engage la société à poursuivre des objectifs sociaux et environnementaux inscrits dans ses statuts. Sa raison d'être est de faciliter l'accès aux pratiques et aux métiers du numérique afin de contribuer à une société plus juste et inclusive.



Figure 1. Siège du groupe Audensiel à Boulogne-Billancourt.

2.1.2 Domaines d'expertise

L'offre du groupe s'organise autour de six pôles d'expertise, présentés dans le tableau 1. Le travail présenté dans ce rapport relève du pôle données et intelligence artificielle, avec des interactions avec le pôle Internet des objets pour ce qui touche à l'acquisition et au traitement des données capteurs.

Pôle	Périmètre
<i>Digital factory</i>	Conception, développement et industrialisation d'applications et de plateformes numériques
Conseil métiers	Cadrage stratégique, conduite du changement et accompagnement de la transformation
Internet des objets	Systèmes embarqués, capteurs, acquisition et traitement de données terrain
Données et intelligence artificielle	Science des données, apprentissage automatique, vision par ordinateur et valorisation des données
Cybersécurité	Audit, sécurisation des systèmes d'information et réponse à incident
Cloud et DevOps	Migration, infrastructure as code, intégration et déploiement continu

Table 1. Pôles d'expertise du groupe Audensiel.

2.1.3 Trajectoire et chiffres clés

Audensiel a connu une croissance soutenue, de l'ordre de 30 % par an depuis sa création, combinant développement organique et acquisitions ciblées. Cette trajectoire a été appuyée par l'entrée au capital de deux partenaires financiers, CAPZA en 2019 puis Sagard en 2022, qui ont permis de financer l'expansion internationale du groupe. Le tableau 2 en résume les principales étapes.

Année	Effectif et implantations	Chiffre d'affaires	Étape marquante
2013	n.d.	n.d.	Création de la société
2019	environ 450 collaborateurs, 12 implantations	> 40 M€	Entrée de CAPZA au capital
2022	environ 1 000 collaborateurs, 16 implantations	> 100 M€	Entrée de Sagard au capital
2024	1 800 collaborateurs, 22 implantations	environ 200 M€	Acquisition de Maltem Canada
2025	2 300 collaborateurs	> 200 M€	Acquisition de Vona

Table 2. Principales étapes du développement du groupe Audensiel.

En une dizaine d'années, le groupe est ainsi passé du statut de structure naissante à

celui d'acteur intermédiaire du conseil en technologies, avec un effectif multiplié par cinq sur les six dernières années.

2.1.4 Implantations

Le groupe est présent sur une vingtaine de sites répartis en Europe et en Amérique. En France, outre le siège de Boulogne-Billancourt, il dispose d'agences à Lille, Nantes, Niort, Rouen, Strasbourg, Lyon, Bordeaux, Toulouse, Aix-en-Provence et Antibes. À l'international, Audensiel est implanté en Belgique, au Luxembourg, en Espagne, en Italie, au Mexique et au Canada.




Figure 2. Implantations du groupe Audensiel.

2.2 Audensiel Innovation, structure d'accueil

Le stage s'est déroulé au sein d'**Audensiel Innovation**, filiale du groupe dédiée à la recherche et au développement, hébergée au siège de Boulogne-Billancourt.

Cette entité se distingue des activités de conseil par son horizon temporel et par la nature de ses livrables. Là où une mission de conseil répond à un besoin client identifié dans un calendrier contraint, Audensiel Innovation conduit des travaux de recherche appliquée pluriannuels, dont certains donnent lieu à des publications scientifiques. La filiale bénéficie à ce titre du statut de **Jeune Entreprise Innovante**, qui reconnaît un effort de recherche et développement significatif rapporté aux charges de l'entreprise.

C'est dans ce cadre que s'inscrivent les travaux présentés ici, menés au sein de l'équipe de recherche et développement sous l'encadrement du **Dr Amira Mimouna**, responsable du projet DriveSense.

2.3 Le projet DriveSense

2.3.1 Objectifs et périmètre

DriveSense, intitulé complet *Système de perception avancé pour la conduite autonome* [1], est un projet de recherche engagé le 3 janvier 2022 et dont l'échéance est fixée au 15 octobre 2027.

Son objectif général est la conception d'un système de perception de l'environnement robuste aux conditions de conduite dégradées. Il se décompose en quatre axes de recherche : la caractérisation des capteurs embarqués et de leurs domaines de validité respectifs ; la fusion multimodale de données ; l'identification du contexte de conduite, notamment météorologique ; et l'évaluation de ces briques sur données réelles comme en simulation.

2.3.2 Travaux antérieurs et continuité

Le stage présenté ici ne constitue pas un point de départ mais s'inscrit dans une progression déjà engagée. Des travaux antérieurs, conduits en 2023 au sein du même projet et sous le même encadrement, avaient posé plusieurs jalons dont ce travail hérite directement.

Contribution antérieure	Contenu
État de l'art	Analyse des méthodes de fusion multimodale et des approches de fusion dynamique, dont AdaFusion, HydraFusion et MT-DETR
Proposition d'architecture	Modèle de fusion adaptative en trois composants : identification du contexte de conduite, module de <i>gating</i> , fusion optimale des données trimodales
Jeu de données simulé	Construction d'un jeu de données sous le simulateur CARLA, comprenant 36 000 acquisitions trimodales couvrant 72 combinaisons d'environnement, dont un sous-ensemble de 11 851 images annotées
Modèle d'identification du contexte	Classifieur météorologique convolutif inspiré de Compact-CNN [2], entraîné sur RADIATE puis sur le jeu simulé

Table 3. Contributions antérieures du projet DriveSense dont ce travail hérite.

Deux éléments de cet héritage méritent d'être explicités. Le premier est le classifieur météorologique. Le module **WeatherCNN** employé dans le *Knowledge Based Gating*, présenté au chapitre 6, dérive directement de ce travail antérieur : l'architecture convolutive, le principe du recadrage de la partie haute de l'image et les dimensions de

prétraitement en proviennent. Il a été réentraîné dans le cadre de ce stage sur les cinq classes météorologiques de RADIATE retenues ici.

Le second est la définition même de la mission. Les perspectives formulées à l'issue des travaux de 2023 identifiaient explicitement comme prochaine étape l'implémentation du module de *gating* et du modèle de fusion dynamique, restés à l'état de proposition. C'est précisément l'objet du présent stage, qui transpose en outre l'approche des données simulées vers les données réelles de RADIATE, un changement de terrain qui introduit ses propres difficultés : synchronisation temporelle effective des capteurs, déséquilibre des classes annotées et hétérogénéité géométrique des modalités.

2.4 Objectifs du stage

Le sujet confié était intitulé **Fusion multimodale adaptative pour véhicules autonomes**.

L'objectif général était de concevoir, d'implémenter et d'évaluer une architecture de perception capable de sélectionner dynamiquement les modalités et les combinaisons de capteurs les plus pertinentes selon le contexte de la scène, plutôt que de les fusionner systématiquement. Cet objectif se décline en cinq sous-objectifs opérationnels.

a) Prise en main des données et caractérisation des modalités. Exploiter le jeu de données RADIATE et son SDK, résoudre la synchronisation temporelle entre radar, LiDAR et caméra stéréo, puis évaluer séparément le comportement d'un détecteur par modalité afin de mesurer objectivement leurs domaines de validité respectifs selon les conditions météorologiques.

b) Résolution du verrou géométrique de la caméra. Le radar et le LiDAR se représentent naturellement dans un espace métrique vu de dessus, ce qui n'est pas le cas de la caméra. Il s'agissait d'identifier et de comparer les stratégies permettant de projeter l'information caméra dans ce même espace, condition nécessaire à une fusion précoce géométriquement cohérente.

c) Première stratégie de sélection : le Knowledge Based Gating. Concevoir une première architecture de fusion sélective pilotée par des règles expertes, la modalité privilégiée étant déterminée par la condition météorologique prédite en ligne par le classifieur hérité des travaux antérieurs. Cette approche, interprétable et directement dérivée des domaines de validité mesurés à l'étape précédente, constituait une première réponse au problème de sélection.

d) Seconde stratégie : PercepFlow et l'Attention Gating. L'évaluation du *Knowledge Based Gating* ayant fait apparaître les limites d'un ensemble de règles fixées

a priori, notamment sur les scènes ambiguës ou mal couvertes par les cinq catégories météorologiques retenues, une seconde architecture a été proposée. **PercepFlow**, nom donné dans ce travail à cette architecture, remplace les règles expertes par un mécanisme de sélection appris qui attribue un score à chaque branche à partir des caractéristiques extraites par les capteurs, sans recourir à aucune règle météorologique explicite.

e) Évaluation quantitative et qualitative des deux stratégies. Entraîner les architectures, mesurer leurs performances au regard des détecteurs monomodaux et l’une par rapport à l’autre, conduire une étude d’ablation sur le nombre de branches activées, et analyser le comportement effectif des modules de sélection sur des scènes représentatives.

Livrables attendus. Les livrables convenus étaient les architectures implémentées et leurs modèles entraînés, les protocoles d’évaluation associés, la documentation des résultats, ainsi qu’un démonstrateur permettant de présenter le fonctionnement du système. Ce dernier a donné lieu à l’interface décrite au chapitre 9.

2.5 Contraintes et périmètre

Le stage s’est déroulé sur une durée de six mois, du 2 mars 2026 au 28 août 2026. Trois contraintes ont structuré les choix techniques.

Contrainte de données. Les travaux ont été menés exclusivement sur données réelles issues de RADIATE, sans recours à la simulation, afin de confronter l’approche à la variabilité effective des conditions de conduite. Ce choix a pour contrepartie un déséquilibre marqué des classes annotées, dont l’incidence sur les résultats est analysée au chapitre 8.

Contrainte de calcul. L’essentiel des entraînements et des évaluations a été conduit sur **Google Colab**, dont les sessions à durée limitée et les ressources graphiques variables ont fortement contraint le budget d’apprentissage. Cette contrainte a pesé en particulier sur le module de projection de la caméra en vue de dessus, dont la distribution de profondeur apprise aurait bénéficié d’un apprentissage plus long, et elle a conduit à écarter les architectures à base de Transformers au profit de Faster R-CNN, sensiblement moins coûteux à entraîner. Les moyens de calcul sont détaillés en section 7.1.

Contrainte de temps. La durée impartie a imposé de hiérarchiser les explorations. Quatre approches d’intégration de la caméra en vue de dessus ont été évaluées avant

qu'une seule ne soit retenue, et l'étude d'ablation sur le nombre de branches activées n'a pu être conduite au-delà de trois branches.

2.6 Organisation et suivi des travaux

2.6.1 Encadrement

Les travaux ont été conduits au sein de l'équipe de recherche et développement d'Audensiel Innovation, sous l'encadrement du Dr Amira Mimouna, responsable du projet DriveSense. Le suivi s'est organisé autour de points d'avancement réguliers avec l'encadrante, complétés par des revues techniques lors des étapes structurantes : validation des évaluations monomodales, arbitrage sur la stratégie de projection de la caméra en espace BEV, et décision de passer d'une sélection par règles à une sélection apprise.

Ce mode de fonctionnement a laissé une autonomie importante dans la conduite des expérimentations, tout en réservant les décisions d'orientation à des points de validation explicites. Les résultats intermédiaires ont été documentés au fur et à mesure, ce qui a permis de constituer progressivement la matière du présent rapport.

2.6.2 Démarche adoptée

La démarche a suivi une progression incrémentale, chaque étape conditionnant la suivante. Il n'était pas possible de concevoir une stratégie de sélection pertinente sans avoir d'abord mesuré les domaines de validité de chaque modalité ; ni d'inclure la caméra dans le processus de sélection sans avoir résolu son incompatibilité géométrique avec l'espace de fusion ; ni enfin de justifier le recours à une sélection apprise sans avoir constaté les limites d'une sélection par règles.

Phase	Objet	Résultat obtenu
1	Prise en main de RADIATE et de son SDK, synchronisation temporelle des capteurs	Triplet synchronisé caméra, radar et LiDAR, exploitable en entrée de fusion
2	Évaluation des détecteurs monomodaux par condition météorologique	Caractérisation des domaines de validité de chaque modalité
3	Intégration de la caméra en vue de dessus	Comparaison de quatre approches, sélection de <i>Lift</i> , <i>Splat</i> , <i>Shoot</i>
4	Première architecture sélective par règles expertes	<i>Knowledge Based Gating</i> opérationnel, limites identifiées
5	Architecture à sélection apprise	PercepFlow, entraînement en deux phases
6	Évaluation, ablation et analyses qualitatives	Résultats quantitatifs et comparaison des deux stratégies
7	Démonstrateur et rédaction	Interface de visualisation et rapport de stage

Table 4. Phases de déroulement du stage.

2.6.3 Planification

La figure 3 présente le déroulement effectif des travaux sur les six mois du stage. Les phases se recouvrent partiellement : l'évaluation monomodale s'est poursuivie pendant l'étude des approches de projection de la caméra, et la rédaction du rapport a été menée en parallèle des dernières expérimentations.




Figure 3. Planification des travaux sur la durée du stage.

CHAPITRE 3

État de l'art

Cette section présente les travaux et méthodes existants sur lesquels s'appuie la contribution. Elle part des capteurs embarqués et de leurs limites intrinsèques, présente les approches de détection d'objets, puis les niveaux et stratégies de fusion de données. Elle examine ensuite les architectures de fusion dynamique, qui constituent le cadre direct de ce travail, et les représentations en vue de dessus permettant d'y intégrer la caméra. Elle se conclut par l'identification des verrous et le positionnement des méthodes proposées.

3.1 Capteurs embarqués pour les systèmes de transport intelligents

Les capteurs de perception embarqués se répartissent en deux familles. Les capteurs **actifs** émettent un signal et exploitent son écho pour caractériser la scène : c'est le cas du radar, du LiDAR et des capteurs à ultrasons. Les capteurs **passifs** se contentent d'enregistrer l'énergie provenant de l'environnement, la caméra en étant l'exemple le plus répandu.

Caméra. La caméra constitue le capteur le plus riche sémantiquement. Elle restitue couleur, texture, contours et apparence, informations indispensables à l'interprétation d'une scène routière, qu'il s'agisse de la lecture de panneaux, du marquage au sol ou de la classification fine des usagers. Les configurations monoculaires servent essentiellement à l'analyse sémantique, tandis que les configurations stéréoscopiques, analogues à la vision binoculaire, permettent une estimation de profondeur par triangulation. Une variante thermique existe, sensible au rayonnement infrarouge, particulièrement efficace de nuit ou en présence de fumée, mais mal adaptée à la mesure de distance. Le principal défaut de la caméra visible reste sa dépendance à l'éclairage et aux conditions météorologiques, à laquelle s'ajoute un coût de traitement élevé.

Radar. Le radar émet et reçoit des ondes électromagnétiques et en déduit directement la distance et la vitesse radiale des cibles, avec un coût de calcul faible. Sa portée est importante et, surtout, sa robustesse face au brouillard, à la pluie, à la neige et à l'obscurité est très supérieure à celle des capteurs optiques. On distingue classiquement les radars courte portée, dédiés à l'aide au stationnement, moyenne portée, pour la prévention des collisions arrière, et longue portée, pour le régulateur de vitesse adaptatif. En contrepartie, sa résolution angulaire est limitée et il génère facilement de fausses alarmes par réflexions parasites.

LiDAR. Le LiDAR balaie l'environnement au moyen d'impulsions laser et produit un nuage de points tridimensionnel décrivant précisément la géométrie de la scène, avec un champ de vision pouvant atteindre 360°. Il fournit ainsi l'information spatiale la plus fiable des trois modalités. Ses limites sont son coût, sa consommation énergétique et surtout sa sensibilité aux phénomènes diffusants tels que le brouillard, la neige ou la poussière, qui perturbent la propagation du faisceau.

Ultrasons. Les capteurs à ultrasons, enfin, sont peu coûteux et utiles à très courte portée, mais leur faible résolution et leur sensibilité au bruit les cantonnent aux manœuvres à basse vitesse. Ils ne sont pas retenus dans ce travail.

Capteur	Apports	Limites	Portée
Radar	Distance et vitesse directes, faible coût de calcul, robuste à la météo et à la nuit	Résolution angulaire limitée, fausses alarmes, sensible aux interférences	5 à 250 m
Caméra visible	Couleur, texture, haute résolution, forte discriminabilité	Sensible à la luminosité et aux intempéries, traitement coûteux, pas de profondeur directe	Variable
Caméra thermique	Robuste aux variations d'illumination, détection aisée des personnes	Occultations, inadaptée à la mesure de distance	Variable
LiDAR	Géométrie 3D précise, large champ de vision	Coût élevé, consommation, sensible au brouillard et à la neige	environ 150 m
Ultrason	Très faible coût	Basse résolution, sensible au bruit, portée très courte	environ 4 m

Table 5. Caractéristiques des principaux capteurs de perception de l'environnement.

Aucun de ces capteurs ne couvre à lui seul l'ensemble des situations de conduite. Chacun échoue dans des conditions où un autre reste opérant : la caméra se dégrade là où le radar demeure fiable, le radar manque de finesse là où le LiDAR excelle. Cette complémentarité, davantage que la redondance, est ce qui motive la fusion multicapteurs.

3.2 Détection d'objets

La détection d'objets consiste à localiser les objets d'intérêt dans une observation et à leur attribuer une classe. Son état de l'art se scinde nettement avant et après l'avènement de l'apprentissage profond.

Approches antérieures à l'apprentissage profond. Elles reposent sur des descripteurs conçus manuellement, associés à des classifieurs classiques. Les classifieurs en cascade de Viola et Jones [25], fondés sur des caractéristiques de Haar et un apprentissage par AdaBoost sur fenêtre glissante, ont constitué une première référence. Les descripteurs HOG de Dalal et Triggs [6], décrivant les orientations de gradients locaux et associés à un classifieur SVM, ont marqué la détection de piétons. Le modèle de pièces déformables de Felzenszwalb *et al.* [8] a introduit une modélisation par parties articulées pour absorber les déformations. Enfin, la recherche sélective d'Uijlings *et al.* [23] génère des propositions de régions par agrégation successive de segments similaires en couleur, texture et taille. Ces méthodes plafonnent en présence de forte variabilité d'apparence et d'illumination.

Détecteurs à deux étages. Les détecteurs par régions produisent d'abord des propositions d'objets, puis les classent et affinent leur localisation. R-CNN [10] en est le précurseur, s'appuyant sur la recherche sélective. SPPnet [12] puis Fast R-CNN [9] introduisent le calcul des caractéristiques une seule fois sur l'image entière, via un réseau convolutif de type VGG ou ResNet [13], ce qui réduit considérablement le coût. Faster R-CNN [20] remplace ensuite la génération externe de propositions par un *Region Proposal Network* appris conjointement, rendant l'ensemble entraînable de bout en bout. Cette famille privilégie la précision de localisation.

Détecteurs à un étage. Ils prédisent directement classes et boîtes sur une grille dense, sans étape de proposition. Ils privilégient la vitesse d'inférence, au prix d'une précision généralement moindre sur les petits objets.

Détecteurs à base de Transformers. L'architecture Transformer [24], initialement conçue pour le traitement du langage, repose sur un mécanisme d'attention qui pondère les relations entre tous les éléments d'une séquence. DETR [4] transpose ce principe à la détection : il formule la tâche comme une prédiction d'ensemble et supprime les composants heuristiques que sont la génération d'ancres et la suppression des non-maxima. DETR simplifie ainsi nettement le pipeline, mais exige un volume de données et un budget d'entraînement considérablement supérieurs à ceux de Faster R-CNN, ainsi qu'une convergence lente. C'est cette dernière considération qui a conduit, dans le présent travail, à retenir Faster R-CNN comme détecteur de base pour l'ensemble

des branches : le volume annoté disponible dans RADIATE et les ressources de calcul du stage ne permettaient pas d'exploiter correctement une architecture de type DETR sur sept branches simultanées.

3.3 Fusion de données pour la perception

La fusion multicapteurs se caractérise d'abord par le **niveau** auquel les informations sont combinées. On distingue classiquement trois niveaux, dont les compromis sont résumés dans le tableau 6.

La **fusion bas niveau**, ou fusion précoce, combine les données brutes ou les représentations très peu transformées, avant tout traitement discriminant. Elle offre le potentiel d'exploitation maximal, puisque le modèle peut apprendre des corrélations intermodales fines. En contrepartie, elle exige que les modalités partagent un espace de représentation commun, et elle est particulièrement vulnérable au bruit : une modalité dégradée contamine directement la représentation fusionnée.

La **fusion intermédiaire** opère sur les cartes de caractéristiques extraites indépendamment de chaque modalité. Elle constitue un compromis entre expressivité et robustesse et reste le régime le plus employé dans les architectures récentes.

La **fusion haut niveau**, ou fusion tardive, combine les décisions finales, typiquement les boîtes englobantes issues de détecteurs indépendants. Elle est robuste à la défaillance d'une modalité, puisque celle-ci n'affecte que sa propre chaîne, mais elle interdit toute exploitation des corrélations intermodales au niveau des caractéristiques.

Niveau	Principe	Atouts	Limites
Précoce	Combinaison des données ou représentations brutes	Exploite les corrélations intermodales fines	Exige un espace commun ; sensible au bruit d'un capteur
Intermédiaire	Combinaison des cartes de caractéristiques	Compromis expressivité / robustesse	Nécessite un alignement des caractéristiques
Tardif	Combinaison des détections finales	Robuste à la défaillance d'une modalité	Aucune corrélation intermodale exploitée

Table 6. Niveaux de fusion multicapteurs et compromis associés.

Algorithmes de fusion tardive. Trois algorithmes reviennent régulièrement pour agréger des ensembles de boîtes issus de détecteurs distincts. La *suppression des non-maxima* (NMS) compare les boîtes deux à deux au moyen de l'intersection sur

union

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}, \quad (1)$$

et ne conserve, parmi celles qui dépassent un seuil de recouvrement, que la boîte au score le plus élevé. Le *Soft-NMS* [3] raffine ce principe : au lieu de supprimer les boîtes redondantes, il atténue leur score par une pondération gaussienne de paramètre σ . Cette variante préserve des détections qu’une suppression stricte éliminerait, au prix d’un risque accru de faux positifs. La *fusion pondérée de boîtes* (WBF) [22] procède différemment : elle regroupe les boîtes en grappes puis calcule, pour chaque grappe, une boîte moyenne pondérée par les scores de confiance, ce qui produit une estimation consensuelle plutôt qu’une sélection.

Un constat contre-intuitif. Un résultat traverse la littérature récente : **fusionner davantage de capteurs n’améliore pas systématiquement la performance**. Lorsqu’une modalité devient bruitée, son intégration peut dégrader la détection finale plutôt que l’enrichir. Ce constat, développé quantitativement en section 3.5, est le point de départ des architectures de fusion sélective.

3.4 Architectures de fusion dynamique

Par opposition à la fusion statique, qui applique un schéma de combinaison fixe quelles que soient les conditions, la **fusion dynamique** adapte sa stratégie au contexte courant. Cette section détaille HydraFusion, travail de référence directement à l’origine du projet, puis situe les principales approches concurrentes.

3.4.1 HydraFusion : formulation et architecture

Formulation du problème. HydraFusion [17] part d’une reformulation de la détection d’objets. Là où une approche classique applique une fonction de détection unique ϕ à l’ensemble des mesures $\mathbf{X}$, les auteurs proposent de considérer ϕ comme un *ensemble* de modèles et d’en sélectionner dynamiquement le sous-ensemble le plus approprié :

$$\Omega = \pi(\mathbf{X}), \quad \phi^* = \rho(\Omega), \quad \mathbf{Y} = \phi^*(\mathbf{X}), \quad (2)$$

où π désigne un modèle d’identification du contexte Ω , et ρ le mécanisme qui sélectionne le sous-ensemble ϕ^* pour ce contexte. L’apport conceptuel tient à ce que le contexte n’est plus une donnée externe mais une représentation apprise à partir des mesures elles-mêmes.

Architecture multi-branches. L’architecture, représentée dans la figure 4, combine fusion précoce et fusion tardive. Les données de chaque modalité traversent d’abord un

réseau convolutif spécifique appelé *stem*, produisant un ensemble de caractéristiques F . Un module de *gating* exploite ces caractéristiques pour identifier le contexte et sélectionner les k branches à exécuter. Chaque branche est un détecteur opérant sur une modalité ou une combinaison de modalités : les branches monomodales permettent d'isoler un capteur fiable lorsque les autres sont dégradés, tandis que les branches multimodales réalisent une fusion précoce par concaténation des caractéristiques de *stems* le long de la dimension des canaux, suivie d'une convolution de fusion. Les détections des branches actives sont enfin agrégées par un bloc de fusion tardive.




Figure 4. Architecture multi-branches de HydraFusion, d'après [17].

Implémentation de référence. Les auteurs implémentent chaque *stem* et chaque branche comme un Faster R-CNN à dorsale ResNet-18, scindée au premier bloc : la partie initiale forme le *stem*, les couches restantes et le réseau de propositions de régions constituent la branche. Avec quatre capteurs, deux caméras, un LiDAR et un radar, le nombre de branches possibles s'élève à $2^4 - 1 = 15$. Les auteurs en retiennent sept, choisies par expertise pour que chacune compense les limites des autres : quatre branches monomodales et trois branches de fusion précoce. L'entraînement utilise une taille de lot de 1, un taux d'apprentissage de 5×10^{-3} pour les *stems* et les branches, et de 5×10^{-5} pour le module de *gating*, entraîné séparément par régression de la perte agrégée de chaque branche.

3.4.2 Les quatre stratégies de *gating*

Quatre mécanismes de sélection sont proposés et comparés.

Stratégie	Principe	Limite
<i>Knowledge Gating</i>	Encodage statique, par expertise, du sous-ensemble de branches à exécuter pour chaque contexte identifié via une source externe	Suppose un ensemble fini de contextes rigide­ment définis
<i>Deep Gating</i>	Réseau convolutif à trois couches suivi d'un perceptron multicouche, appris pour estimer la perte de chaque branche	Traite uniformément l'ensemble de la carte de caractéristiques
<i>Attention Gating</i>	Ajout d'une couche d'auto-attention avant le perceptron, produisant une carte d'attention sur les caractéristiques	Moindre interprétabilité de la décision
<i>Optimal Gating</i>	Classement des branches selon leur perte réelle mesurée <i>a posteriori</i>	Non déployable : sert de borne supérieure théorique

Table 7. Stratégies de *gating* proposées dans HydraFusion [17].

Le *Knowledge Gating* s'appuie sur les métadonnées de RADIATE, qui décrivent le type de scène de chaque séquence. L'ensemble de contextes retenu est {ville, autoroute, carrefour, rural, neige, brouillard, nuit}, et le classement des capteurs dans chaque contexte est établi à partir de connaissances expertes. Les deux stratégies apprises définissent au contraire le contexte comme un espace de caractéristiques continu, ce qui permet de modéliser des situations que des catégories discrètes ne captent pas.

3.4.3 Résultats rapportés et enseignements

Le tableau 8 rassemble les performances obtenues sur RADIATE, avec une répartition 70/30 entre entraînement et test.

Famille	Configuration	mAP
Aucune fusion	Caméra unique	65,33 %
	Radar	69,42 %
	LiDAR	61,86 %
Fusion précoce	Caméras gauche et droite	65,33 %
	Radar + LiDAR	71,63 %
	Caméra + LiDAR	65,99 %
Fusion tardive	Caméras gauche et droite	65,71 %
	Radar + LiDAR + caméras	71,16 %
	Toutes les branches (précoce + tardive)	65,47 %
HydraFusion	Top-3 branches, WBF	74,54 %
	Top-3 branches, NMS	78,51 %
	Top-3 branches, Soft-NMS	81,31 %

Table 8. Performances de détection rapportées sur RADIATE [17].

Deux lignes de ce tableau méritent une attention particulière. La configuration exécutant *toutes* les branches n’atteint que 65,47 % de mAP, soit moins que plusieurs configurations à deux capteurs et près de 16 points de moins que la sélection des trois meilleures. C’est la démonstration quantitative la plus directe du constat énoncé en section 3.3 : la sélectivité, et non l’exhaustivité, est le levier de robustesse.

Le tableau 9 croise ensuite les stratégies de *gating* et le nombre de branches activées.

Stratégie (fusion)	$k = 1$	$k = 3$	$k = 5$	$k = \text{tout}$
<i>Knowledge Gating</i> (NMS)	77,59 %	76,37 %	76,53 %	75,81 %
<i>Deep Gating</i> (NMS)	67,43 %	78,14 %	73,31 %	75,81 %
<i>Attention Gating</i> (Soft-NMS)	67,27 %	81,31 %	69,88 %	65,71 %
<i>Optimal Gating</i> (Soft-NMS)	73,03 %	81,57 %	72,93 %	65,71 %

Table 9. Performances selon la stratégie de *gating* et le nombre k de branches activées [17].

Trois enseignements s’en dégagent. D’abord, l’*Attention Gating* domine à $k = 3$ et n’accuse qu’un retard de 0,26 point sur l’*Optimal Gating*, ce qui suggère qu’une sélection apprise sur les caractéristiques capte l’essentiel du signal utile. Ensuite, $k = 3$ constitue l’optimum pour les deux stratégies apprises, tandis que les performances s’effondrent

au-delà : l'*Attention Gating* perd près de 16 points entre $k = 3$ et l'activation de toutes les branches. Enfin, le *Knowledge Gating* obtient paradoxalement son meilleur score à $k = 1$, ce que les auteurs attribuent à la suffisance de la connaissance experte pour désigner la meilleure modalité unique dans un contexte donné. Ils soulignent toutefois qu'un déploiement réel ne saurait s'appuyer sur $k = 1$, une configuration sans redondance face à l'obstruction ou à la panne d'un capteur.

Coût matériel rapporté par les auteurs. Pour établir la faisabilité d'un déploiement embarqué, les auteurs d'HydraFusion mesurent énergie, latence et occupation mémoire de leur implémentation sur une plateforme Nvidia Drive PX2, référence industrielle du domaine. La configuration à trois branches avec *Attention Gating* consomme 3,28 J par échantillon, pour une latence de 73,0 ms et 1080 Mo de mémoire. Ces chiffres sont comparables à ceux d'une fusion tardive à quatre capteurs, qui atteint 3,77 J et 84,3 ms. L'argument est important : HydraFusion peut se substituer à une fusion tardive dans un système existant sans surcoût matériel, tout en offrant une mAP nettement supérieure. La configuration à cinq branches, plus coûteuse et moins performante, est écartée. Cette évaluation matérielle est propre à l'article de référence ; elle n'a pas été reproduite dans le présent travail, dont les moyens de calcul sont décrits en section 7.1.

3.4.4 Autres approches de fusion dynamique

AdaFusion. AdaFusion [14] introduit une pondération adaptative entre caractéristiques visuelles et LiDAR pour la reconnaissance de lieux. L'approche module l'importance relative de chaque modalité, mais elle reste une pondération continue et n'écarte jamais complètement une source, contrairement à une sélection par branches.

EcoFusion. EcoFusion [16], issu de la même équipe qu'HydraFusion, aborde la fusion sous l'angle de l'efficacité énergétique et ajuste la stratégie selon des indices contextuels. Le critère d'optimisation y est le compromis entre performance et consommation, plutôt que la seule robustesse.

MT-DETR. MT-DETR [5] exploite un mécanisme de fusion pondérée par la confiance sur caméra, LiDAR et radar, dans un cadre à base de Transformers. L'approche gagne en expressivité mais hérite des besoins en données et en calcul propres à cette famille d'architectures.

ASF : fusion consciente de la disponibilité. Plus récemment, ASF [18] formalise explicitement le problème de la *disponibilité* des capteurs. Les auteurs distinguent deux familles : la fusion fortement couplée, qui combine directement les cartes de

caractéristiques et suppose donc que tous les capteurs fonctionnent correctement, et la fusion par attention croisée entre capteurs, plus tolérante à la dégradation mais dont le coût de calcul croît avec le nombre de fragments traités. Leur proposition repose sur une projection canonique unifiée qui rend les caractéristiques de tous les capteurs cohérentes entre elles, complétée par une attention croisée par fragments. Sur le jeu de données K-Radar, ASF rapporte des gains de 9,7 points en AP_{BEV} et de 20,1 points en AP_{3D} au seuil $IoU = 0,5$. Ce travail confirme deux intuitions centrales du présent projet : la nécessité d'un espace de représentation commun avant toute fusion précoce, et l'importance de ne pas présupposer la disponibilité continue de chaque modalité.

Approche	Mécanisme d'adaptation	Modalités	Limite principale
AdaFusion [14]	Pondération continue apprise	Caméra, LiDAR	N'écarte jamais totalement une modalité
HydraFusion [17]	Sélection discrète de k branches parmi 7	Caméra, LiDAR, radar	Caméra traitée hors de l'espace de fusion précoce
EcoFusion [16]	Adaptation selon indices contextuels	Caméra, LiDAR, radar	Optimise l'énergie plus que la robustesse
MT-DETR [5]	Pondération par la confiance	Caméra, LiDAR, radar	Coût d'entraînement des Transformers
ASF [18]	Attention croisée par fragments, projection canonique	Caméra, LiDAR, radar 4D	Évalué sur K-Radar uniquement

Table 10. Synthèse comparative des approches de fusion dynamique.

Limite commune. La plupart de ces modèles sont entraînés et évalués sur des jeux de données qui sous-représentent la diversité réelle des conditions environnementales. Leur robustesse annoncée reste donc à confirmer face à la variété des scénarios auxquels un véhicule autonome est effectivement exposé. C'est ce constat qui justifie, dans ce travail, le recours à un jeu de données spécifiquement construit autour des conditions dégradées.

3.5 Robustesse aux dégradations : l'apport des travaux d'évaluation

Une littérature récente, distincte des travaux de conception d'architectures, s'attache à *mesurer* systématiquement la robustesse des détecteurs face aux dégradations. Ces travaux fournissent la justification quantitative du recours à une fusion sélective.

Corruptions courantes en détection 3D. Dong *et al.* [7] conçoivent 27 types de dégradations affectant les entrées LiDAR et caméra, réparties en cinq familles : météorologiques, liées au capteur, liées au mouvement, liées à l’objet et liées à l’alignement. En les synthétisant sur des jeux de données publics, ils construisent trois bancs d’essai de robustesse et y évaluent 24 modèles de détection 3D. Trois conclusions ressortent. Les dégradations liées au mouvement sont les plus pénalisantes et affectent l’ensemble des modèles. Les modèles fusionnant LiDAR et caméra se montrent plus robustes que les modèles monomodaux. Enfin, les modèles reposant uniquement sur la caméra sont extrêmement vulnérables aux dégradations d’image, ce qui souligne le caractère indispensable de l’information géométrique.

Corruptions multicapteurs simultanées. MSC-Bench [11] pousse l’analyse plus loin en considérant 16 combinaisons de dégradations affectant caméra et LiDAR, isolément ou simultanément. Les auteurs relèvent que les méthodes de fusion sont habituellement évaluées sur des données non dégradées, ce qui laisse dans l’ombre leur comportement réel en conditions difficiles. Leur évaluation de six modèles de détection 3D et de quatre modèles de construction de cartes met en évidence des dégradations de performance substantielles en conditions météorologiques adverses et en cas de défaillance de capteur. Ils insistent en particulier sur une vulnérabilité propre aux systèmes multicapteurs, absente des systèmes monomodaux : les problèmes de désalignement spatial et de décalage temporel entre modalités.

Conséquences pour ce travail. Ces deux études convergent vers un constat qui structure la démarche adoptée ici. Une architecture de fusion qui suppose la disponibilité et la fiabilité continues de toutes ses entrées est intrinsèquement fragile, puisqu’une dégradation localisée se propage à l’ensemble de la représentation fusionnée. Elles justifient également l’attention portée dans ce rapport à la synchronisation temporelle des capteurs, traitée au chapitre 4, dont MSC-Bench montre qu’elle constitue une source de dégradation à part entière.

3.6 Représentations en vue de dessus et projection de la caméra

Une architecture de fusion précoce impose que les modalités partagent un espace de représentation commun. La vue de dessus, ou *Bird’s-Eye View* (BEV), s’impose naturellement dans le contexte automobile : elle correspond à l’espace métrique dans lequel s’effectuent la planification de trajectoire et l’évitement d’obstacles, et le radar comme le LiDAR s’y projettent directement, chaque cellule correspondant à une position réelle (x, y) .

La caméra fait exception. Elle fournit une image en perspective frontale où chaque pixel encode une direction de vue sans profondeur associée. Concaténer directement

des caractéristiques caméra avec des caractéristiques radar ou LiDAR produit donc une fusion géométriquement incohérente. Plusieurs familles de solutions existent.

La **triangulation stéréoscopique** reconstruit la profondeur à partir de la disparité entre deux vues, selon $z = f \cdot B/d$. Elle repose sur une géométrie exacte, mais les algorithmes d'appariement échouent sur les surfaces uniformes, dans les zones occultées et à grande distance, produisant des reconstructions très lacunaires.

La **transformation perspective inverse** projette l'image dans le plan du sol par une homographie $H = K_{\text{BEV}} \cdot [R|t] \cdot K^{-1}$ calculée à partir des paramètres de calibration. Elle est immédiate et ne nécessite aucun apprentissage, mais elle repose sur l'hypothèse d'un monde plan : tout objet vertical est projeté de manière erronée et laisse une traînée d'artefacts.

Les approches **fondées sur une distribution de profondeur apprise** lèvent cette hypothèse. *Lift*, *Splat*, *Shoot* [19] prédit, pour chaque pixel, une distribution de probabilité discrète sur un ensemble de profondeurs candidates, ainsi qu'un vecteur de caractéristiques. Le produit externe de ces deux quantités engendre un frustum tridimensionnel, étape *Lift*. Ce volume est ensuite projeté dans une grille BEV par accumulation, à partir des paramètres de calibration, étape *Splat*. La carte BEV obtenue alimente enfin la tâche cible, étape *Shoot*. L'ensemble étant différentiable, la distribution de profondeur est apprise conjointement avec la tâche, ce qui évite tout recours à une supervision de profondeur explicite ou à une hypothèse géométrique rigide. Le coût est un besoin d'entraînement sensiblement plus important.

Une famille plus récente s'affranchit entièrement de l'estimation de profondeur. BEVFormer [15] définit une grille de requêtes en vue de dessus et interroge, pour chaque cellule, les régions pertinentes des images au moyen d'une attention croisée spatiale, complétée par une attention temporelle qui agrège récursivement l'information des instants antérieurs. Les auteurs justifient ce choix par la sensibilité des méthodes fondées sur la profondeur à la qualité de l'estimation : une profondeur imprécise engendre des erreurs qui se propagent dans toute la représentation. Ils rapportent par ailleurs une amélioration notable du rappel en conditions de faible visibilité, ce qui est directement pertinent pour la problématique traitée ici. Le prix à payer est un coût d'entraînement considérablement supérieur et un besoin en données multi-caméras que RADIATE, doté d'une seule caméra stéréo frontale, ne satisfait pas. Cette famille d'approches a donc été écartée pour ce travail, mais elle constitue une perspective naturelle si le dispositif d'acquisition venait à évoluer.

3.7 Verrous identifiés et positionnement de la contribution

L'analyse de l'état de l'art fait apparaître trois verrous.

Verrou 1 : quelles modalités combiner ? Chaque capteur possède un domaine de validité propre, et les travaux d'évaluation [7, 11] confirment qu'une fusion indiscriminée peut nuire à la performance dès qu'une entrée se dégrade. Déterminer, pour une scène donnée, quelles modalités ou quelles combinaisons privilégier constitue une question ouverte, dont HydraFusion [17] montre l'importance quantitative : sur RADIATE, activer les sept branches fait perdre près de 16 points de mAP par rapport à la sélection des trois meilleures.

Verrou 2 : à quel niveau fusionner ? Fusion précoce, intermédiaire ou tardive impliquent des compromis opposés entre expressivité et robustesse au bruit, résumés dans le tableau 6. La fusion précoce suppose en outre une homogénéité de représentation que la caméra ne satisfait pas nativement, difficulté qu'ASF [18] traite par une projection canonique unifiée.

Verrou 3 : selon quelle stratégie de sélection ? Une sélection fondée sur des règles expertes est interprétable et prévisible, mais reste limitée aux situations anticipées lors de leur définition. Une sélection apprise s'adapte aux cas ambigus, au prix d'une moindre interprétabilité.

Démarche adoptée. Ces verrous ont été abordés successivement. Le troisième a d'abord été traité par une approche à règles expertes, le *Knowledge Based Gating*, qui présente l'avantage d'être directement interprétable puisque la condition météorologique prédite détermine explicitement les capteurs privilégiés. Les limites de cette approche, à savoir sa dépendance à la qualité de la prédiction météorologique et surtout son incapacité à traiter les situations non couvertes par les règles définies à l'avance, ont ensuite motivé le passage à une sélection apprise, au cœur de PercepFlow.

Positionnement de PercepFlow. L'architecture proposée dans ce travail reprend le principe multi-branches à *gating* de HydraFusion et l'applique au jeu de données RADIATE, avec sept branches et une sélection des trois meilleures par *Attention Gating*, fusionnées par Soft-NMS. Elle s'en distingue toutefois sur un point structurant. Dans HydraFusion, la caméra est traitée dans son espace perspective natif et ses détections sont reprojétées vers le repère de fusion en aval, ce qui suppose une hypothèse de hauteur fixe des objets et, surtout, exclut de fait la caméra du mécanisme de sélection précoce. PercepFlow projette au contraire les caractéristiques caméra en espace BEV au moyen d'un module *Lift, Splat, Shoot*, de sorte que les trois modalités présentent une représentation homogène en entrée du module de sélection. La caméra devient ainsi un candidat à part entière du processus de *gating*, et les branches la faisant intervenir réalisent une véritable fusion précoce géométriquement cohérente.

Cette différence répond directement à la limite identifiée dans le tableau 10 pour HydraFusion, et rejoint le principe d'espace de représentation commun que défend ASF [18].

Une seconde différence tient au protocole comparatif : les deux stratégies de sélection, apprise et guidée par la connaissance, sont ici évaluées sur le même jeu de test, la seconde s'appuyant sur une prédiction météorologique produite en ligne par un classifieur dédié plutôt que sur des métadonnées de contexte fournies avec le jeu de données.

CHAPITRE 4

Jeu de données et capteurs utilisés

4.1 Présentation du jeu de données RADIATE

Ce travail s'appuie sur **RADIATE**, acronyme de *RAdar Dataset In Adverse weaTher*, constitué par l'université Heriot-Watt et publié en 2021 [21]. Il regroupe des données radar, LiDAR, caméra stéréo et GPS/IMU collectées sur routes ouvertes dans des conditions météorologiques variées.

Le choix de ce jeu de données répond directement à la problématique traitée. Comme le soulignent les travaux d'évaluation présentés en section 3.5, la plupart des architectures de fusion sont entraînées et validées sur des données acquises en conditions favorables, ce qui laisse leur robustesse réelle largement indéterminée. RADIATE a été explicitement construit pour combler ce manque : il constitue le premier jeu de données public associant un radar haute résolution à un grand nombre d'acteurs routiers annotés sur voie publique, avec des acquisitions en brouillard dense et en chutes de neige abondantes.

4.1.1 Volume et organisation

Le jeu de données représente **117 Go** au format compressé et se compose de **60 séquences** d'acquisition. Compte tenu de ce volume et de l'environnement de calcul retenu, décrit en section 7.1, les données ont été stockées sur un espace Google Drive monté dans les sessions de travail, ce qui évite un retransfert à chaque démarrage mais introduit un coût de lecture non négligeable lors des phases d'entraînement.

Les acquisitions annotées se répartissent en sept scénarios combinant condition météorologique et type d'environnement : ensoleillé à l'arrêt, ensoleillé ou couvert en milieu urbain, couvert sur autoroute, nuit sur autoroute, pluie en zone périurbaine, brouillard en zone périurbaine et neige en zone périurbaine.

4.1.2 Dispositif d'acquisition

Les quatre capteurs sont montés sur le toit d'un véhicule utilitaire, selon la disposition présentée en figure 5. Le radar est placé le plus en hauteur pour dégager son champ de vision sur 360°, le LiDAR et la caméra stéréo étant disposés en avant de celui-ci.




Figure 5. Disposition des capteurs sur le véhicule d'acquisition RADIATE.

Le tableau 11 détaille les caractéristiques de chaque capteur. Trois points appellent un commentaire. La résolution de la caméra, de 672×376 pixels, est modeste au regard des standards actuels, ce qui limite la finesse de détection des objets éloignés. Le radar ne fournit *pas* d'information Doppler, si bien que la vitesse radiale des cibles n'est pas directement disponible et que seule la signature spatiale peut être exploitée. Enfin, les trois capteurs opèrent à des fréquences différentes, ce qui rend indispensable l'étape de synchronisation traitée en section 4.3.

Capteur	Modèle	Caractéristiques
Radar	Navtech CTS350-X	Radar à balayage, couverture 360° , portée maximale 100 m, résolution en distance 0,175 m, résolutions angulaires en azimuth et en élévation de $1,8^\circ$, sans information Doppler
LiDAR	Velodyne HDL-32E	32 canaux, 10 Hz, couverture 360°
Caméra	ZED (stéréo)	672×376 pixels par voie, 15 images par seconde, boîtier étanche pour conditions extrêmes
GPS/IMU	Advanced Navigation	Position, orientation et accélérations

Table 11. Caractéristiques des capteurs de la plateforme RADIATE [21].

4.1.3 Comportement des modalités en conditions dégradées

La figure 6 illustre le comportement des trois modalités dans cinq conditions d'acquisition. Elle donne à voir, sur données réelles, le phénomène qui motive l'ensemble de ce travail.




Figure 6. Comportement des trois modalités selon la condition d'acquisition.

En conditions ensoleillées, les trois modalités fournissent une information exploitable. De nuit, la caméra perd l'essentiel de son contenu sémantique tandis que le radar conserve une signature nette. Dans le brouillard, la caméra est presque entièrement obturée et le nuage LiDAR se réduit à quelques points épars, le faisceau laser étant diffusé par les gouttelettes en suspension ; le radar reste en revanche pleinement lisible. Sous la pluie et sous la neige, la caméra est floutée ou masquée par les dépôts sur l'optique, et le LiDAR se dégrade fortement.

Ce constat visuel recoupe exactement les mesures quantitatives rapportées au chapitre 6 : le score F1 de la caméra chute à 9,2 % sous la neige, tandis que le radar demeure la modalité la plus stable. Il fonde également le comportement observé du module de sélection de PercepFlow, analysé au chapitre 8.

4.1.4 Formats de données

Chaque séquence regroupe les flux des différents capteurs dans des répertoires distincts, accompagnés d'un fichier d'horodatage associant à chaque numéro de trame un instant d'acquisition en temps UNIX. Le tableau 12 récapitule les représentations mises à disposition et signale celles qui sont exploitées dans ce travail.

Représentation	Description	Utilisée ici
Navtech_Polar	Image radar brute en coordonnées polaires, 400×576 (azimut $\times$ distance)	Non
Navtech_Cartesian	Projection cartésienne de l'image polaire, 1152×1152 , chaque pixel couvrant $0,17 \times 0,17$ m	Oui
velo_lidar	Nuage de points brut au format $(x, y, z, \text{intensité}, \text{canal})$	Oui
lidar_bev_image	Vue de dessus du nuage LiDAR, aux dimensions de l'image radar cartésienne	Oui
zed_left / zed_right	Images stéréo non rectifiées, 672×376	Oui
camera_{left,right}_image	Images rectifiées, accompagnées d'annotations 2D approchées	Oui
proj_lidar_{left,right}_point	Points LiDAR projetés dans le repère caméra	Non
GPS_IMU_Twist	Position, orientation, vitesses angulaires et accélérations	Non

Table 12. Représentations disponibles dans RADIATE et usage dans ce travail.

L'existence d'une représentation `lidar_bev_image` aux dimensions exactes de l'image radar cartésienne est un élément déterminant pour ce projet : elle offre d'emblée un espace commun au radar et au LiDAR, et réduit le verrou géométrique à la seule modalité caméra.

4.1.5 Calibration et repère de référence

Les paramètres intrinsèques et les coefficients de distorsion de la caméra stéréo ont été estimés par les auteurs, permettant la génération d'images rectifiées. Pour la calibration extrinsèque, **le radar est retenu comme origine du repère local**, en tant que capteur principal du dispositif. Les positions du LiDAR et des deux caméras sont exprimées comme des transformations à six degrés de liberté relativement à ce repère, obtenues par mesure directe des distances entre capteurs puis affinées par alignement des mesures. Ces paramètres sont fournis dans un fichier de configuration du SDK.

Ce choix du radar comme origine est repris dans ce travail, tant pour la projection des caractéristiques caméra en vue de dessus que pour la synchronisation temporelle, où le radar sert également de référence.

4.1.6 Structure des annotations

Les annotations sont fournies au format JSON. Chaque objet y est décrit par un identifiant, un nom de classe et une boîte englobante définie par la position de son coin supérieur gauche, sa largeur, sa hauteur et un angle de rotation exprimé en degrés dans le sens trigonométrique.

Le recours à des boîtes *orientées* constitue une particularité de ce jeu de données, cohérente avec la nature de la représentation radar : dans un espace métrique vu de dessus, l'orientation d'un véhicule est une information géométrique pertinente, ce qu'elle n'est pas dans une image en perspective. Les auteurs signalent par ailleurs que les annotations projetées dans le repère caméra sont approchées, estimées à partir d'une hypothèse de route plane et d'une hauteur moyenne par classe. Cette limite est à garder à l'esprit lors de l'interprétation des visualisations projetées vers la vue caméra, présentées au chapitre 9.

4.1.7 Distribution des classes annotées

Huit classes d'objets sont annotées : voiture, van, camion, bus, moto, vélo, piéton et groupe de piétons.




Figure 7. Distribution des objets annotés dans RADIATE, par classe et par scénario.

La figure 7 met en évidence un **fort déséquilibre entre les classes**. Les véhicules sont largement majoritaires, tandis que les piétons, vélos et motos sont beaucoup moins représentés. Ce déséquilibre n'est pas un défaut du jeu de données mais le reflet de la composition réelle du trafic routier. Il n'en constitue pas moins une difficulté d'apprentissage majeure, dont l'incidence directe est analysée au chapitre 8 : les classes rares y obtiennent une précision moyenne de 19,09 %, contre 52,96 % pour les classes véhicules.




Figure 8. Durée des scénarios RADIATE et part annotée.

La figure 8 montre en outre que toutes les données disponibles ne sont pas annotées. Les scénarios de brouillard et de neige, précisément les plus intéressants pour la problématique traitée, comptent parmi les moins annotés proportionnellement. Les parties annotées constituent la base de l'entraînement supervisé et de l'évaluation quantitative ; leur répartition entre ensembles est détaillée en section 7.2, et la composition de l'ensemble de test figure en annexe C.

4.2 Capteurs embarqués de la plateforme RADIATE

Les principes de fonctionnement, les apports et les limites génériques de ces trois familles de capteurs ont été présentés en section 3.1. Cette sous-section précise uniquement les modèles effectivement embarqués sur la plateforme RADIATE et la manière dont leurs données sont exploitées dans ce travail.

Le radar est un **Navtech CTS350-X**, dont la sortie cartésienne fournit directement une représentation en vue de dessus exploitable sans transformation. Le LiDAR est un **Velodyne HDL-32E** ; son nuage de points est projeté dans une représentation compatible avec le même espace BEV. La caméra est une **caméra stéréo ZED** ; contrairement aux deux précédents, elle fournit une image en perspective frontale, ce qui impose une projection géométrique spécifique traitée en section 6.2.

Capteur	Modèle	Exploitation dans ce travail
Radar	Navtech CTS350-X	Image cartésienne 1152×1152 , BEV native
LiDAR	Velodyne HDL-32E	Nuage de points projeté en image BEV
Caméra stéréo	ZED	Image perspective, projetée en BEV par <i>Lift</i> , <i>Splat</i> , <i>Shoot</i>

Table 13. Capteurs de la plateforme RADIATE et représentation retenue.

4.3 Synchronisation temporelle des capteurs par le SDK RADIATE

L'exploitation du jeu de données RADIATE nécessite une étape préalable de synchronisation temporelle entre les capteurs. Le radar Navtech fonctionne à environ 4 Hz, tandis que la caméra stéréo ZED et le LiDAR Velodyne opèrent à des fréquences plus élevées. Par conséquent, utiliser directement le même indice de frame pour les trois modalités ne garantit pas que les données correspondent au même instant physique.

Dans une scène dynamique, un véhicule ou un piéton peut se déplacer entre deux acquisitions. Sans synchronisation, les informations issues du radar, du LiDAR et de la caméra pourraient représenter des états légèrement différents de la scène, ce qui poserait un problème pour une architecture de fusion dont les caractéristiques doivent décrire les mêmes objets au même moment.

Le SDK RADIATE résout ce problème par une synchronisation fondée sur les timestamps. Le radar est utilisé comme référence temporelle principale. Pour une frame radar donnée, le SDK récupère le timestamp correspondant, puis recherche dans les autres modalités les acquisitions les plus proches temporellement. Le principe de sélection repose sur la méthode `get_id`, qui minimise l'écart temporel absolu :

$$i_s^* = \arg \min_i |t_s(i) - t_{\text{ref}} + \Delta_s|, \quad (3)$$

où i_s^* désigne l'indice sélectionné pour le capteur s , $t_s(i)$ le timestamp de la frame i , t_{ref} le timestamp de référence fourni par le radar, et Δ_s l'offset de synchronisation associé au capteur.

La méthode `get_from_timestamp` applique ensuite cette recherche à chaque modalité et retourne un triplet synchronisé composé d'une image caméra, d'un scan LiDAR et d'un scan radar. Ce triplet constitue l'entrée cohérente utilisée par PercepFlow pour l'extraction des caractéristiques et la sélection des branches.

Remarque sur l'indexation des frames. Dans le SDK RADIATE, l'indice d'accès à une frame correspond à une position dans le tableau des timestamps (base 0). Comme les fichiers RADIATE sont nommés à partir de 000001.png, l'indice Python n correspond au fichier $\{n+1\}$.png. Par exemple, l'indice 150 correspond au fichier 000151.png.

Indice demandé	Signification	Fichier radar associé
frame = 0	1 ^{er} scan radar	000001.png
frame = 150	151 ^e scan radar	000151.png
frame = 574	575 ^e scan radar	000575.png

Table 14. Correspondance entre indice Python et fichier radar.

Exemple sur la séquence *city_1_1*. Pour l'indice radar 150 de la séquence *city_1_1*, le timestamp de référence est $t_{\text{ref}} = 1549985852,715$ s. Le triplet synchronisé obtenu est présenté dans le tableau 15.

Modalité	Frame sélectionnée	Fichier chargé	Écart temporel
Radar	000151	Navtech_Cartesian/000151.png	0 ms
Caméra	000576	zed_left/000576.png	260 ms
LiDAR	000385	velo_lidar/000385.csv	289 ms

Table 15. Triplet synchronisé pour *city_1_1*.



Figure 9. Synchronisation temporelle des capteurs par le SDK RADIATE.

Cet exemple illustre que les trois modalités ne partagent pas le même numéro de fichier. L'écart temporel résiduel est contrôlé par la stratégie de sélection du timestamp le plus proche, conformément à l'équation (3). Cette synchronisation est essentielle pour garantir que les données utilisées par PerceFlow décrivent une scène temporellement cohérente avant l'extraction des caractéristiques et la sélection des branches.

CHAPITRE 5

Problématique

La perception multicapteurs repose sur l'hypothèse que les capteurs embarqués apportent des informations complémentaires. En pratique, cette complémentarité dépend fortement du contexte opérationnel. Une caméra peut devenir peu fiable sous la pluie, dans le brouillard ou de nuit, tandis que le radar conserve une meilleure robustesse. Le LiDAR apporte une information géométrique utile, mais peut aussi être perturbé par certaines conditions atmosphériques.

La question centrale n'est donc pas uniquement de fusionner plusieurs capteurs, mais de déterminer quelles modalités ou quelles combinaisons doivent être privilégiées pour une scène donnée. Une fusion systématique peut introduire du bruit lorsque certaines sources sont dégradées ; à l'inverse, une sélection trop restrictive risque de supprimer des informations pertinentes.

On considère un ensemble de données multicapteurs :

$$X = \{X_{\text{radar}}, X_{\text{lidar}}, X_{\text{camera}}\}. \quad (4)$$

L'objectif est de produire un ensemble de détections :

$$Y = \{(b_i, c_i, s_i)\}_{i=1}^N, \quad (5)$$

où b_i désigne la boîte englobante, c_i la classe prédite et s_i le score de confiance.

La problématique générale peut être formulée ainsi :

Comment concevoir une architecture de perception multicapteurs capable de sélectionner dynamiquement les branches les plus pertinentes pour la détection d'objets, tout en tenant compte du contexte météorologique et de l'hétérogénéité géométrique des modalités radar, LiDAR et caméra ?

CHAPITRE 6

Architecture PercepFlow

6.1 Évaluation préalable des détecteurs monomodaux

Avant la mise en place de la fusion sélective, les détecteurs associés à chaque capteur ont été évalués séparément sur un ensemble représentant environ 30 % des 60 séquences totales de RADIATE. Cette évaluation concerne uniquement les détecteurs monomodaux ; elle est distincte de l'évaluation finale de PercepFlow, réalisée ensuite sur environ 40 % des 60 séquences totales de RADIATE. Cet ensemble monomodal couvre sept conditions météorologiques et environnementales distinctes : brouillard, pluie, neige, nuit, ville, carrefour et autoroute. Cette étape permet d'identifier le comportement individuel de chaque modalité selon le contexte et de justifier l'utilisation d'une stratégie de fusion adaptative.

Modalité	Modèle	Représentation	Statut
Radar	Faster R-CNN R101-FPN	Radar BEV (Navtech)	Préentraîné RADIATE, utilisé directement
LiDAR	Faster R-CNN R50-FPN	LiDAR BEV (Velodyne)	Réentraîné dans ce travail
Caméra	Faster R-CNN ResNet50-FPN	Image perspective	Préentraîné COCO, utilisé directement

Table 16. Détecteurs monomodaux évalués.

6.1.1 Détecteur radar

Le modèle radar est un Faster R-CNN R101-FPN préentraîné sur les données radar RADIATE en toutes conditions météorologiques. Il prend en entrée des images radar cartésiennes de résolution 1152×1152 pixels et détecte les objets dans un espace BEV. Le seuil de confiance est fixé à 0,5 et le seuil IoU à 0,5.

La figure 10 présente les performances globales obtenues sur l'ensemble monomodal.




Figure 10. Performances globales du détecteur radar sur l'ensemble monomodal.

Le radar affiche un rappel supérieur à sa précision, ce qui traduit une bonne capacité à retrouver les objets présents au prix de fausses détections liées aux réflexions parasites. Son score F1 de 61,56 % en fait la modalité la plus équilibrée des trois.

6.1.2 Détecteur caméra

Le modèle caméra est un Faster R-CNN ResNet50-FPN préentraîné sur COCO et appliqué directement aux images de la caméra droite rectifiée de RADIATE (`camera_right_rect`), sans réentraînement spécifique. Ce choix introduit un décalage de domaine entre les données COCO et les scènes routières de RADIATE. Cette évaluation constitue une baseline monomodale en espace image perspective. Elle ne correspond pas directement à la branche caméra finale de PercepFlow, qui repose ensuite sur une représentation BEV obtenue par LSS.

La figure 11 présente les performances globales obtenues sur l'ensemble monomodal.




Figure 11. Performances globales du détecteur caméra sur l'ensemble monomodal.

Le rappel élevé (63,19 %) associé à une précision limitée (39,93 %) traduit un nombre important de fausses détections, cohérent avec le décalage de domaine entre COCO et les scènes RADIATE. La figure 12 détaille ce comportement selon la condition

météorologique. Ses meilleures performances sont obtenues sous la pluie ($F1 = 70,8 \%$) et en conditions claires ($F1 = 54,9 \%$). En revanche, elle échoue très nettement sous la neige ($F1 = 9,2 \%$, rappel = $5,0 \%$) et de nuit ($F1 = 29,0 \%$), deux conditions où la visibilité optique est fortement dégradée.




Figure 12. Performances du détecteur caméra selon la condition météorologique.

6.1.3 Détecteur LiDAR BEV

Le modèle LiDAR est un Faster R-CNN R50-FPN réentraîné dans ce travail sur des images BEV générées à partir des nuages de points Velodyne HDL-32E de RADIATE. L'entraînement de ce détecteur externe restreint les huit classes de RADIATE à cinq catégories effectivement prédites : voiture, bus, camion, van et piéton. Les classes moto, vélo et groupe de piétons ne sont pas produites par ce détecteur, ce qui contribue à ses faibles performances sur les classes rares. Cette restriction est propre au détecteur monomodal LiDAR ; PercepFlow conserve pour sa part les huit classes d'origine.

Sous-ensemble	Nombre d'images
Entraînement	23 372
Validation	5 101
Test	4 451
Total	32 924

Table 17. Données de réentraînement du LiDAR BEV.

La figure 13 présente les performances globales obtenues sur l'ensemble monomodal.




Figure 13. Performances globales du détecteur LiDAR BEV sur l'ensemble monomodal.

Le LiDAR BEV présente le profil le plus faible des trois modalités, avec un rappel de 21,66 % qui traduit un nombre important d'objets non détectés. La figure 14 détaille ce comportement selon la condition météorologique.




Figure 14. Performances du détecteur LiDAR BEV selon la condition météorologique.

6.1.4 Synthèse comparative




Figure 15. Comparaison globale des trois détecteurs monomodaux.

Ces résultats mettent en évidence des profils de performance très différents selon les modalités. Le radar offre la meilleure robustesse globale ($F1 = 61,56\%$) et maintient des performances cohérentes en conditions dégradées. La caméra atteint un rappel comparable ($63,19\%$) mais avec une précision nettement inférieure, et s'effondre la nuit et sous la neige. Le LiDAR BEV présente les performances globales les plus faibles ($F1 = 29,02\%$, $mAP = 15,44\%$), avec un rappel particulièrement bas, mais conserve un intérêt sur les scènes claires et structurées, notamment en ville et aux carrefours. Ses limites peuvent s'expliquer par un entraînement encore restreint et par la difficulté à apprendre correctement les classes rares. Chaque modalité domine ainsi dans un régime distinct : le radar sous le brouillard, la nuit et aux carrefours, la caméra sous la pluie et en conditions claires, le LiDAR BEV sur les scènes claires et structurées. Ces différences de comportement selon le contexte météorologique justifient l'utilisation d'une stratégie de fusion sélective.

6.2 Intégration de la caméra en BEV : approches étudiées

Le verrou géométrique posé par la caméra et les familles de solutions existantes ont été exposés en section 3.6. Quatre approches ont été implémentées et évaluées expérimentalement dans le cadre de ce travail ; cette section rend compte des mesures obtenues et de la décision retenue pour chacune. Les trois premières ont été écartées, la quatrième a été retenue pour la branche caméra de PercepFlow.

6.2.1 Approche 1 : BEV stéréo par SGBM

La caméra ZED est une caméra stéréo dont la baseline connue permet de reconstruire la profondeur par triangulation. L'algorithme SGBM (*Semi-Global Block Matching*)

calcule une carte de disparité selon $\text{profondeur} = f \cdot B/d$, où f est la focale, B la baseline et d la disparité. Le nuage 3D résultant est ensuite projeté dans le plan BEV. Cette approche est écartée car la couverture de la représentation BEV obtenue est insuffisante pour un CNN : sur une image 512×512 , moins de 7 850 pixels sur 262 144 portent une information fiable (0,4 à 3 % de couverture). SGBM échoue sur les surfaces uniformes, les zones occultées et aux grandes distances.

6.2.2 Approche 2 : caméra frontale avec Faster R-CNN natif et fusion tardive



Cette approche conserve la caméra dans son espace perspective natif et lui dédie un Faster R-CNN indépendant, la fusion étant réalisée au niveau des détections finales par reprojection des boîtes caméra dans l'espace BEV avant Soft-NMS. Elle est écartée pour deux raisons majeures. D'abord, la reprojection des boîtes image vers le BEV repose sur une hypothèse de hauteur fixe des objets, introduisant des erreurs croissantes avec la distance. Surtout, cette architecture empêche le module de *gating* de pondérer la caméra selon le contexte : la caméra est exclue du processus de sélection et ne rejoint le pipeline qu'au niveau de la fusion tardive.

6.2.3 Approche 3 : IPM (Inverse Perspective Mapping)

L'IPM est une transformation homographique qui projette l'image perspective dans le plan du sol en vue BEV, en calculant une homographie $H = K_{\text{BEV}} \cdot [R|t] \cdot K^{-1}$ à partir des paramètres de calibration. La représentation BEV obtenue partage le même espace que le radar et le LiDAR, permettant l'intégration directe dans les branches caméra de PercepFlow. La zone utile représente environ 25 % de l'image BEV. Sa limite principale est que les objets verticaux ne sont pas projetés correctement, laissant des artefacts étalés. Bien que compatible avec le pipeline BEV sans apprentissage, l'IPM a finalement été écartée au profit de LSS : les artefacts introduits sur les objets verticaux, précisément ceux que le système doit détecter, dégradent la représentation là où elle importe le plus.

6.2.4 Approche 4 : Lift, Splat, Shoot

L'approche *Lift, Splat, Shoot* [19] est un module PyTorch entraînable de bout en bout qui prédit la distribution de profondeur de chaque pixel et projette les caractéristiques visuelles dans la grille BEV. L'étape *Lift* associe à chaque pixel une distribution de profondeur discrète sur $D = 24$ bins log-espacés entre 2 et 52 mètres, produisant un frustum 3D de dimensions $[B, 64, D, H', W']$. L'étape *Splat* projette ce volume dans une grille BEV par `scatter_add` à partir des paramètres de calibration. L'étape *Shoot* exploite la carte BEV $[B, 64, 128, 128]$ pour la détection par Faster R-CNN BEV.

Figure 16. Principe de l'étape *Lift*.Figure 17. Architecture générale de *Lift*, *Splat*, *Shoot*.

La sortie $[B, 64, 128, 128]$ a exactement la même forme que les sorties des stems radar et LiDAR, ce qui la rend directement fusionnable dans toutes les branches impliquant la caméra. Le module de *gating* reçoit ainsi une entrée homogène de $[B, 192, H/4, W/4]$ sans hétérogénéité spatiale.

Approche	Principe	Limite principale	Décision
SGBM stéréo	Triangulation stéréo, projection BEV	Couverture BEV : 0,4 à 3 %	Écartée
Caméra frontale	Faster R-CNN natif, fusion tardive des boîtes	Gating impossible, reprojection approx.	Écartée
IPM	Homographie plan sol, transformation fixe	Artefacts sur objets verticaux, 25 % zone utile	Écartée
LSS	Distribution profondeur apprise, projection BEV	Nécessite plus d'entraînement	Retenue

Table 18. Approches d'intégration caméra en BEV.

6.3 Vue d'ensemble des deux architectures dynamiques

Deux architectures de fusion sélective ont été développées successivement. La première, le *Knowledge Based Gating*, sélectionne les capteurs privilégiés au moyen de règles expertes déclenchées par la condition météorologique prédite. La seconde, **PercepFlow**, repose sur un mécanisme d'*Attention Gating* qui apprend à sélectionner dynamiquement, à partir des caractéristiques extraites par les capteurs, les branches de détection les plus pertinentes pour chaque scène. Les deux méthodes partagent le même jeu de branches et le même bloc de fusion finale, ce qui permet d'attribuer les écarts de performance au seul mécanisme de sélection.

Méthode	Information utilisée	Principe de sélection
<i>Knowledge Based Gating</i> (première approche)	Condition météo prédite par WeatherCNN	Règles expertes fondées sur la fiabilité attendue des capteurs
PercepFlow (<i>Attention Gating</i>)	Caractéristiques extraites par les <i>stems</i>	Scores appris pour sélectionner les branches les plus pertinentes

Table 19. Présentation des deux méthodes étudiées, dans leur ordre de développement.


Un socle de branches commun. Les deux méthodes s'appuient sur le même ensemble de sept branches de détection, correspondant aux trois modalités prises isolément et à leurs quatre combinaisons possibles. Elles partagent également le même bloc de fusion finale par Soft-NMS. Seul le mécanisme qui décide des branches à activer les distingue : des règles expertes déclenchées par la condition météorologique pour le *Knowledge Based Gating*, des scores appris sur les caractéristiques pour PercepFlow. Cette architecture commune est ce qui rend la comparaison des deux approches significative, puisque tout écart de performance est imputable à la seule stratégie de sélection.

Branche	Capteurs utilisés
radar	Radar seul
lidar	LiDAR seul
camera	Caméra seule
radar_lidar	Radar et LiDAR
camera_radar	Caméra et radar
camera_lidar	Caméra et LiDAR
all	Radar, LiDAR et caméra

Table 20. Les sept branches de détection, communes aux deux méthodes de sélection.

6.4 Première approche : Knowledge Based Gating

Le *Knowledge Based Gating* est la première méthode de sélection étudiée dans ce travail. Elle est guidée par le contexte météorologique et repose sur un ensemble de règles expertes définies *a priori*. Le module WeatherCNN prend en entrée une image caméra et prédit une condition parmi cinq classes : brouillard, nuit, normal, pluie et neige. La condition prédite active ensuite un profil de fusion défini par des règles expertes, qui détermine lesquelles des sept branches du tableau 20 sont privilégiées.

Figure 18. Architecture du *Knowledge Based Gating*.

Condition prédite	Profil de fusion privilégié
Normal	Caméra et LiDAR (visibilité favorable)
Brouillard	Radar prioritaire
Pluie	Radar et LiDAR favorisés
Neige	Radar prioritaire
Nuit	Radar et LiDAR favorisés

Table 21. Règles du *Knowledge Based Gating*.

Algorithm 1 Sélection par *Knowledge Based Gating*

Entrée : Image caméra X_{camera} , règles de sélection R **Sortie :** Profil de fusion P , branches privilégiées $\mathcal{S}$

- 1: $w \leftarrow \text{WeatherCNN}(X_{\text{camera}})$
 - 2: $P \leftarrow R(w)$
 - 3: Définir $\mathcal{S}$ selon le profil P
 - 4: Exécuter les branches de $\mathcal{S}$ et pondérer leurs sorties
 - 5: $Y \leftarrow \text{SoftNMS}(\text{détectations de } \mathcal{S})$
 - 6: **return** $P, \mathcal{S}$
-

Limites constatées. Cette approche présente l'avantage d'être entièrement interprétable : pour toute prédiction, le profil de fusion activé est connu et justifiable. Son évaluation a toutefois fait apparaître trois limites. D'abord, les règles ne couvrent que les cinq conditions prévues et ne traitent pas les scènes ambiguës ou intermédiaires. Ensuite, elles raisonnent capteur par capteur et ne peuvent donc pas privilégier une combinaison de modalités qui n'aurait pas été anticipée. Enfin, et c'est la limite la plus structurelle, la prédiction météorologique repose sur une image caméra : la méthode dépend ainsi de la modalité précisément la plus fragile dans les conditions dégradées qu'elle cherche à traiter. Ces constats ont motivé le passage à un mécanisme de sélection appris, présenté dans la section suivante.

6.5 Architecture PercepFlow : Attention Gating

L'*Attention Gating* est le mécanisme de sélection au cœur de PercepFlow. Contrairement à l'approche précédente, il calcule un score pour chaque branche de détection à partir des seules caractéristiques extraites par les capteurs, sans règle météorologique explicite ni dépendance à une modalité particulière pour identifier le contexte. L'architecture prend en entrée trois modalités : radar, LiDAR et caméra. Chaque modalité est traitée par un module d'extraction de caractéristiques, appelé *stem*, basé sur un ResNet-18 tronqué produisant une représentation $[B, 64, H/4, W/4]$. Les représentations sont ensuite utilisées par les sept branches Faster R-CNN présentées dans le tableau 20. Le module de sélection conserve les k meilleures branches, avec $k = 3$ dans cette étude.




Figure 19. Architecture générale de PercepFlow.

Le module de sélection calcule un score pour chaque branche à partir de la concaténation F des caractéristiques extraites par les *stems* :

$$p = G(F), \quad p \in \mathbb{R}^7, \quad (6)$$

et les branches actives sont sélectionnées par :

$$\mathcal{S}_k = \text{TopK}(p, k). \quad (7)$$

Algorithm 2 PercepFlow : fusion sélective par *Attention Gating*

Entrée : $X_{\text{radar}}, X_{\text{lidar}}, X_{\text{camera}}, k$

Sortie : Détections finales Y , branches sélectionnées $\mathcal{S}_k$

```

1:  $F_{\text{radar}} \leftarrow S_{\text{radar}}(X_{\text{radar}})$ 
2:  $F_{\text{lidar}} \leftarrow S_{\text{lidar}}(X_{\text{lidar}})$ 
3:  $F_{\text{camera}} \leftarrow S_{\text{camera}}(X_{\text{camera}})$ 
4:  $F \leftarrow \text{Concat}(F_{\text{radar}}, F_{\text{lidar}}, F_{\text{camera}})$ 
5:  $p \leftarrow G(F)$  (scores des 7 branches)
6:  $\mathcal{S}_k \leftarrow \text{TopK}(p, k)$ 
7:  $D \leftarrow \emptyset$ 
8: for chaque branche  $B_j \in \mathcal{S}_k$  do
9:    $D \leftarrow D \cup B_j(F_j)$ 
10: end for
11:  $Y \leftarrow \text{SoftNMS}(D)$ 
12: return  $Y, \mathcal{S}_k$ 

```

CHAPITRE 7

Protocole expérimental et entraînement

7.1 Moyens de calcul

L'ensemble des développements, des entraînements et des évaluations a été réalisé sur **Google Colab Pro**, plateforme de calcul infonuagique donnant accès à des accélérateurs graphiques dans un environnement de type carnet de notes. Les accélérateurs effectivement alloués au cours du stage ont été principalement des **NVIDIA T4** et, pour les entraînements les plus exigeants, des **NVIDIA A100**. Le jeu de données RADIATE, dont le volume est présenté en section 4.1.1, a été stocké sur un espace Google Drive monté dans les sessions de travail. Ce choix d'environnement, dicté par les moyens disponibles, présente des avantages et des limites qu'il convient d'explicitier car ils ont directement influencé les décisions de conception.

L'environnement offre un accès immédiat à un accélérateur graphique sans configuration matérielle préalable, ainsi qu'une chaîne logicielle préinstallée pour PyTorch et Torchvision. Le stockage des jeux de données et des points de sauvegarde s'effectue sur un espace distant monté dans la session, ce qui évite de retransférer les données à chaque démarrage. L'abonnement Pro donne par ailleurs accès à des accélérateurs plus performants et à des sessions plus longues que l'offre gratuite, ce qui s'est révélé nécessaire au vu du volume des données.

Trois limitations ont en revanche structuré le protocole. Les sessions sont d'abord de durée bornée et peuvent être interrompues, ce qui interdit les entraînements longs d'un seul tenant et impose une sauvegarde régulière de l'état du modèle afin de pouvoir reprendre un apprentissage interrompu. Le type d'accélérateur attribué varie ensuite d'une session à l'autre, entre T4 et A100 selon la disponibilité, si bien que les durées d'entraînement ne sont pas directement comparables entre deux exécutions. S'y ajoute le coût d'accès aux données : les séquences résidant sur un espace distant, les temps de lecture ont constitué un facteur limitant lors des phases d'entraînement. La mémoire graphique disponible, enfin, a contraint la taille de lot et, par conséquent, le nombre d'*epochs* réalisables dans le temps imparti.

Ces contraintes expliquent plusieurs choix rapportés dans ce document : le recours à Faster R-CNN plutôt qu'à une architecture à base de Transformers, dont la convergence lente aurait été incompatible avec ce cadre ; l'entraînement de PercepFlow en deux phases séparées plutôt qu'en une seule passe de bout en bout ; et le budget d'apprentissage restreint accordé au module de projection de la caméra en vue de dessus, identifié comme une limite dans la discussion du chapitre 10.

Aucune évaluation sur cible embarquée n'a été conduite. Les mesures d'énergie, de latence et d'occupation mémoire rapportées en section 3.4 proviennent de la littérature et ne caractérisent pas l'implémentation présentée ici.

7.2 Répartition des données

Les 60 séquences de RADIATE sont réparties en trois ensembles disjoints, dont la composition est donnée dans le tableau 22. L'ensemble de test n'intervient à aucun moment de l'entraînement ni de la sélection du modèle ; sa composition nominative figure en annexe C.

Ensemble	Séquences	Images annotées
Entraînement	30	16 716
Validation	6	4 195
Test	22	11 338
Total	58	32 249

Table 22. Répartition des séquences RADIATE entre les trois ensembles.

Les deux séquences restantes des 60 que compte le jeu de données ne comportent pas d'annotations exploitables et sont écartées. L'évaluation finale est conduite avec un seuil d'intersection sur union fixé à 0,5.

Cette répartition ne doit pas être confondue avec l'ensemble utilisé pour l'évaluation préalable des détecteurs monomodaux en section 6.1, constitué de 17 séquences et distinct de l'ensemble de test final.

7.3 Entraînement de PercepFlow

7.3.1 Organisation en phases

L'entraînement s'organise en phases successives, chacune n'optimisant qu'une partie des paramètres.

La **Phase A** est consacrée à l'apprentissage des branches Faster R-CNN, le module de sélection étant gelé afin d'obtenir des branches stables. Elle a d'abord porté sur les branches radar, LiDAR et radar-LiDAR, avant d'étendre l'apprentissage aux sept branches. Une **phase intermédiaire** a ensuite été nécessaire pour réentraîner les quatre branches faisant intervenir la caméra, après l'introduction du module de projection *Lift*, *Splat*, *Shoot* : seules ces quatre branches y sont optimisées, les autres paramètres restant figés.

La **Phase B** entraîne le module de *gating* ainsi que les trois *stems*, les sept branches étant cette fois figées. Ce point mérite d’être souligné car il diffère d’un simple entraînement du module de sélection : les représentations produites par les *stems* sont ajustées conjointement au *gating*, ce qui permet à l’extracteur de caractéristiques de se spécialiser pour la tâche de sélection plutôt que pour la détection.

Composant	Phase A	Phase intermédiaire	Phase B
RadarStem, LidarStem, CameraStem	Figés	Figés	Entraînés
Branches sans caméra	Entraînées	Figées	Figées
Branches avec caméra	Entraînées	Entraînées	Figées
Module de sélection	Gelé	Gelé	Entraîné
Sélection Top- k	Inactive	Inactive	Active, $k = 3$

Table 23. Paramètres optimisés à chaque phase d’entraînement.

7.3.2 Configuration d’entraînement

Le tableau 24 rassemble les hyperparamètres des trois phases. L’optimiseur retenu est AdamW dans tous les cas, avec des taux d’apprentissage distincts selon les groupes de paramètres : un taux plus faible pour les dorsales préentraînées, plus élevé pour les têtes et le module de sélection.

Paramètre	Phase A	Phase intermédiaire	Phase B
Optimiseur	AdamW	AdamW	AdamW
Taux d’apprentissage	dorsale 5×10^{-5} , têtes 5×10^{-4}	dorsale 3×10^{-5} , têtes 3×10^{-4}	<i>stems</i> 10^{-4} , <i>gate</i> 10^{-3}
Décroissance des poids	10^{-4}	10^{-4}	10^{-4}
Ordonnanceur	Cosine, $T_{\max} = 50$, $\eta_{\min} = 10^{-6}$	StepLR, pas 15, $\gamma = 0,1$	Cosine, $T_{\max} = 20$, $\eta_{\min} = 10^{-6}$
Taille de lot	6	4	8
Époques	50 prévues	30 prévues	20 prévues, modèle retenu à l’époque 6
Critère de sélection	mAP de validation	perte d’entraînement	perte de <i>gating</i>

Table 24. Hyperparamètres des phases d’entraînement.

Les paramètres $\beta_1 = 0,9$, $\beta_2 = 0,999$ et $\varepsilon = 10^{-8}$ correspondent aux valeurs par défaut d'AdamW. La graine aléatoire est fixée à 42 et propagée aux générateurs Python, NumPy et PyTorch. Aucune option de déterminisme complet des noyaux CUDA n'a en revanche été activée, si bien que la reproductibilité bit à bit n'est pas garantie.

7.3.3 Fonctions de perte

Les phases A et intermédiaire minimisent la somme directe des pertes produites par Faster R-CNN, à savoir les pertes de classification et de régression du réseau de propositions de régions et de la tête de détection, sans pondération externe.

La Phase B optimise une perte spécifique au module de sélection :

$$\mathcal{L}_{\text{gate}} = \sum_{i=1}^7 p_i \mathcal{L}_i - \lambda H(p), \quad \lambda = 0,30, \quad (8)$$

où $p = \text{softmax}(G(F))$ désigne la distribution produite par le module de sélection, $\mathcal{L}_i$ la perte de la branche i calculée sans propagation de gradient, et $H(p) = -\sum_i p_i \log p_i$ l'entropie de la distribution.

Le premier terme incite le module à attribuer un poids élevé aux branches dont la perte est faible, donc aux branches performantes sur la scène courante. Le second terme, un régularisateur d'entropie, s'oppose à l'effondrement de la distribution sur une branche unique et maintient une exploration des combinaisons. Le critère de sélection du modèle final découle directement de cette formulation : la Phase B n'optimisant que le mécanisme de sélection, c'est la perte de *gating* qui mesure le plus directement la qualité de l'objectif poursuivi, et c'est donc elle qui détermine le point de sauvegarde retenu.

7.3.4 Composition des lots

Les lots de la Phase B sont constitués de manière homogène par condition météorologique, chaque lot ne contenant que des images d'une même condition. Ce choix est cohérent avec l'objectif poursuivi : le module de sélection doit apprendre à associer un contexte à un sous-ensemble de branches, et des lots mélangeant plusieurs conditions produiraient un signal d'apprentissage moyenné sur des situations hétérogènes.

L'augmentation de données est active durant l'entraînement. Elle combine un retournement horizontal synchronisé entre les trois modalités et les boîtes annotées, avec une probabilité de 0,5, et une transformation photométrique appliquée indépendamment à chaque modalité avec la même probabilité, faisant varier le contraste dans $[0,8; 1,2]$ et la luminosité dans $[-15; 15]$.

7.4 Détails d'implémentation de l'architecture

Cette section précise les choix d'implémentation retenus, complétant la présentation fonctionnelle du chapitre 6.

Modules d'extraction de caractéristiques. Les *stems* radar et LiDAR reprennent les premières couches d'un ResNet-18, jusqu'au premier bloc résiduel inclus, et produisent une représentation à 64 canaux au quart de la résolution d'entrée. Le *stem* caméra suit une logique différente, imposée par la projection en vue de dessus : le réseau descend jusqu'au deuxième bloc résiduel, puis une tête d'estimation de profondeur et une projection ramènent la sortie sur 64 canaux, afin d'obtenir la même forme que les deux autres modalités.

Module de sélection. Les trois représentations sont concaténées le long de la dimension des canaux, formant un tenseur à 192 canaux. Celui-ci traverse deux convolutions 3×3 avec normalisation par lots et activation ReLU, ramenant la profondeur à 128 canaux, puis un bloc d'attention de canaux de type *Squeeze-and-Excitation* qui comprime la représentation de 128 à 16 canaux avant de la restituer. Un moyennage global fait ensuite disparaître les dimensions spatiales, et un perceptron à deux couches, de 128 vers 64 puis vers 7, produit un score par branche. Un softmax normalise ces scores, dont les trois plus élevés déterminent les branches activées.

Fusion des caractéristiques dans les branches multimodales. Chaque branche dispose de son propre réseau de détection à pyramide de caractéristiques. La combinaison des modalités s'opère par **addition des niveaux de pyramide de même résolution**, et non par concaténation suivie d'une convolution. Ce choix préserve la dimension des cartes de caractéristiques et évite d'introduire des paramètres supplémentaires par branche. La contribution de la caméra est pondérée avant addition, ce qui permet de moduler son influence dans les branches où elle intervient.

Formats des représentations. Les trois modalités sont redimensionnées en 512×512 avant traitement. Le module *Lift, Splat, Shoot* construit un volume de 24 intervalles de profondeur répartis logarithmiquement entre 2 et 52 mètres, projeté ensuite en une carte de vue de dessus de 64 canaux en 128×128 , identique en forme aux sorties des *stems* radar et LiDAR.

7.5 Entraînement de WeatherCNN

Le classificateur météorologique employé par le *Knowledge Based Gating* est un réseau convolutif compact, hérité des travaux antérieurs du projet DriveSense et réentraîné sur les images caméra de RADIATE.

Son architecture reste volontairement légère, la tâche de classification en cinq conditions étant nettement plus simple que la détection d'objets. L'entrée est une image en niveaux de gris de 100×691 pixels, obtenue en redimensionnant l'image caméra puis en conservant sa partie haute, zone où se concentrent les indices météorologiques que sont le ciel, la luminosité et la visibilité de l'horizon. Le réseau enchaîne deux convolutions de noyau 9×9 et de pas 2, chacune suivie d'une normalisation par lots et d'une activation ReLU, puis deux couches denses ramenant la représentation aux cinq classes de sortie : brouillard, nuit, normal, pluie et neige.

Élément	Valeur
Entrée	Image en niveaux de gris, 100×691 px
Couches convolutives	Deux couches, noyau 9×9 , pas 2
Couches denses	Deux couches, sortie à 5 classes
Classes de sortie	brouillard, nuit, normal, pluie, neige
Modèle retenu	Époque 3, exactitude de validation de 98,6 %

Table 25. Configuration du classificateur WeatherCNN.

7.6 Métriques d'évaluation

Les performances de détection sont évaluées avec les métriques suivantes, calculées avec un seuil IoU de 0,5 :

$$\text{Précision} = \frac{TP}{TP + FP}, \quad \text{Rappel} = \frac{TP}{TP + FN}, \quad (9)$$

$$F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}, \quad (10)$$

$$\text{AP} = \int_0^1 p(r) dr, \quad \text{mAP} = \frac{1}{C} \sum_{c=1}^C \text{AP}_c, \quad (11)$$

où TP , FP et FN désignent respectivement les vrais positifs, faux positifs et faux négatifs, $p(r)$ la précision en fonction du rappel, et C le nombre de classes.

L'analyse distingue deux regroupements de classes. Les **classes véhicules** rassemblent la voiture, le van, le camion et le bus ; les **classes rares** rassemblent le piéton, le groupe de piétons, la moto et le vélo. Ce second groupe correspond aux usagers vulnérables, les moins représentés dans les annotations et les plus difficiles à détecter en vue de dessus.

Fusion des détections. Les boîtes produites par les trois branches actives sont agrégées par un *Soft-NMS* à pondération gaussienne, de seuil d'intersection sur union égal à 0,5 et de paramètre $\sigma = 0,3$. Contrairement à une suppression stricte, cette variante atténue le score des détections redondantes plutôt que de les éliminer, ce qui préserve les objets détectés par une seule branche.

Comparabilité des résultats. Les détecteurs monomodaux évalués en section 6.1 sont des modèles préexistants, évalués avec leurs protocoles propres, dont les seuils diffèrent de ceux retenus ici. Leurs performances caractérisent le domaine de validité de chaque modalité et motivent le recours à une fusion sélective ; elles ne constituent pas une comparaison strictement équitable avec PercepFlow. En revanche, la comparaison entre PercepFlow et le *Knowledge Based Gating*, présentée au chapitre 8, porte sur le même ensemble de test, les mêmes branches et le même bloc de fusion.

Enfin, le comportement du module de sélection de PercepFlow est étudié à travers la fréquence d'activation de chaque branche selon la condition météorologique.

CHAPITRE 8

Résultats et analyse

8.1 Performances globales de PercepFlow

PercepFlow atteint une mAP de 36,02 % sur l'ensemble de test. Le score F1 au seuil de confiance 0,60 est de 60,3 %, avec une précision de 57,8 % et un rappel de 63,1 %.




Figure 20. Performances globales de PercepFlow sur l'ensemble de test (seuil de score 0,60).

Méthode	mAP	Précision	Rappel	F1
<i>Knowledge Based Gating</i>	29,01 %	23,98 %	64,11 %	34,91 %
PercepFlow	36,02 %	57,80 %	63,10 %	60,30 %

Table 26. Comparaison des deux stratégies de sélection sur l'ensemble de test.

Le tableau 26 confronte les deux stratégies de sélection étudiées. La comparaison est directe : les deux méthodes partagent les mêmes sept branches de détection, le même bloc de fusion par Soft-NMS et le même ensemble de test. Tout écart de performance est donc imputable au seul mécanisme qui décide des branches à activer. Les deux approches atteignent un rappel équivalent, de 63,10 % pour PercepFlow contre 64,11 % pour le *Knowledge Based Gating*. C'est sur la précision que l'écart se creuse, avec 57,80 % contre 23,98 %, soit près de 34 points. Autrement dit, la sélection par règles expertes retrouve autant d'objets, mais au prix d'un volume de fausses détections bien supérieur : en activant des branches sur la seule foi de la condition météorologique, elle laisse contribuer des modalités peu fiables dans la scène courante. La sélection apprise, elle, écarte ces branches et produit un ensemble de détections nettement plus propre, d'où un F1 de 60,30 % contre 34,91 %.

Le rappel supérieur à la précision indique que PercepFlow détecte une proportion importante des objets présents, mais produit encore des fausses détections. Le seuil de score retenu, fixé à 0,60, privilégie délibérément le rappel : le balayage du seuil montre que le score F1 maximal, de 0,630, serait atteint pour un seuil de 0,93. En conduite autonome, manquer un usager de la route est toutefois plus coûteux qu'émettre une fausse détection, que les étages ultérieurs de la chaîne de traitement peuvent filtrer. Ce choix de seuil est donc assumé.

8.2 Ablation sur le nombre de branches sélectionnées

Afin d'évaluer l'impact du nombre de branches activées à chaque inférence, trois configurations sont comparées : $k = 3$ (configuration de référence), $k = 2$ et $k = 1$.




Figure 21. Impact du nombre de branches sélectionnées k sur les performances.

Les performances progressent de manière monotone avec k , le gain le plus net apparaissant entre $k = 2$ et $k = 3$ sur la mAP. Ce comportement se distingue de celui rapporté par HydraFusion [17], où l'activation de branches supplémentaires au-delà de trois dégradait les résultats. Sur RADIATE et avec les branches retenues ici, aucune saturation n'est observée jusqu'à $k = 3$, ce qui suggère que l'exploration de valeurs supérieures mériterait d'être conduite.

8.3 Résultats par classe




Figure 22. Précision moyenne par classe sur l'ensemble de test.

La mAP moyenne des classes véhicules atteint 52,96 %, contre 19,09 % pour les classes rares. Cet écart est cohérent avec le déséquilibre des annotations illustré dans la figure 7.

8.4 Analyse des classes rares

Les performances plus faibles sur les classes rares s'expliquent par trois facteurs principaux. Ces classes apparaissent moins souvent dans les données, ce qui limite l'apprentissage. Les vélos, motos et piétons occupent une surface réduite dans les représentations BEV. Enfin, les conditions dégradées peuvent encore réduire leur visibilité. Les faibles AP des classes rares reflètent donc à la fois les limites de l'architecture et les contraintes du jeu de données.

8.5 Comportement du module d'Attention Gating

L'analyse des fréquences de sélection, présentée dans la figure 23, révèle un comportement très structuré. Avec $k = 3$, une branche systématiquement retenue représente environ 33 % des sélections. Trois branches multimodales, `camera_radar`, `radar_lidar` et `all`, se partagent la quasi-totalité des activations et atteignent ce plafond sur les séquences en conditions claires. Les branches `camera`, `lidar` et `camera_lidar` ne sont jamais sélectionnées : le module a appris qu'aucune combinaison excluant le radar n'était compétitive sur RADIATE, ce qui rejoint le constat de l'évaluation monomodale.




Figure 23. Fréquence de sélection des branches par le module d'*Attention Gating*, selon la condition météorologique.

La branche **radar** seule constitue la variable d'ajustement. Absente en conditions claires, elle apparaît dès que la visibilité se dégrade : 6 % sous la pluie, 8 % dans le brouillard, 10 % de nuit et jusqu'à 18 % sous la neige. Ce classement suit l'ordre de dégradation de la caméra mesuré en section 6.1, où le score F1 chutait à 9,2 % sous la neige. Le module d'*Attention Gating* retrouve donc, à partir des seules caractéristiques extraites par les *stems* et sans aucune règle météorologique, la hiérarchie de fiabilité des capteurs que le *Knowledge Based Gating* devait recevoir explicitement. C'est le résultat le plus significatif concernant le comportement du module de sélection.

8.6 Expérimentations avec le Knowledge Based Gating et WeatherCNN

8.6.1 Résultats du classificateur WeatherCNN

Le classificateur météorologique atteint une accuracy de 97,0 % et un score F1 macro de 97,0 % sur l'ensemble de test.




Figure 24. Performances du classificateur WeatherCNN par classe météorologique.

Les meilleurs résultats sont obtenus pour les classes neige, brouillard et nuit, dont les caractéristiques visuelles sont très distinctives. La classe **normal** présente le score le plus faible ($F1 = 94,0 \%$), ce qui est cohérent avec sa définition regroupant plusieurs contextes visuellement hétérogènes.

8.6.2 Analyse qualitative des stratégies de gating

Une analyse qualitative a été réalisée sur trois séquences représentatives de RADIATE : une scène urbaine en conditions favorables (**city_1_1**), une scène pluvieuse (**rain_2_0**) et une scène enneigée (**snow_1_0**). Pour chaque méthode, les figures présentent les détections produites par chaque modalité prise séparément, puis le résultat de la fusion finale projeté vers la vue caméra.




Figure 25. Analyse qualitative du *Knowledge Based Gating*.

Knowledge Based Gating. Dans la scène **city_1_1** (frame 50, conditions normales), la caméra produit 9 détections avec une bonne précision sémantique, le LiDAR 9 détections géométriques précises, et le radar 18 détections sur une zone plus large dont certaines sont des fausses détections. La fusion guidée par le profil **normal** conserve 11 détections cohérentes projetées vers la vue caméra.

Dans la scène **rain_2_0** (pluie), la caméra est fortement dégradée (4 détections avec précision réduite). Le LiDAR maintient de bonnes performances. Le radar reste robuste (9 détections). WeatherCNN prédit une condition pluvieuse et active le profil favorisant le radar et le LiDAR. La fusion récupère 13 détections exploitables.

Dans la scène **snow_1_0** (neige), la caméra ne produit qu'une seule détection fiable. Le profil activé favorise le radar, et la fusion maintient 5 détections malgré la dégradation générale.




Figure 26. Analyse qualitative de PercepFlow.

PercepFlow (Attention Gating). Dans la scène **city_1_1** (conditions normales), la caméra produit 2 détections précises sur les véhicules proches. Le radar fournit une représentation BEV large. Le LiDAR apporte la structure géométrique complémentaire. Le module d'*Attention Gating* sélectionne dynamiquement les branches multimodales les plus pertinentes et la fusion produit une sortie plus complète que chaque capteur seul.

Dans la scène **rain_2_0** (pluie), sans règle météo explicite, le module apprend à réduire le poids des branches caméra et à favoriser le radar et le LiDAR, dont les caractéristiques sont plus stables. La fusion maintient des détections exploitables là où la caméra seule échoue.

Dans la scène **snow_1_0** (neige), le module s'appuie principalement sur le radar, dont la signature BEV reste discriminante malgré la dégradation visuelle. La fusion produit une détection exploitable malgré la quasi-absence de signal utile dans l'image caméra.

Comparaison synthétique. Les deux méthodes confirment que la fusion multicapteurs apporte un gain par rapport à l'utilisation d'une modalité unique dans tous les contextes testés. Le *Knowledge Based Gating* est interprétable et prévisible, ce qui en fait un outil utile pour l'analyse et le débogage. PercepFlow s'avère toutefois nettement plus performant, avec une mAP de 36,02 % contre 29,01 % et surtout un F1 de 60,30 % contre 34,91 %. Trois facteurs expliquent cet écart. La condition météorologique n'est qu'un indicateur indirect de la fiabilité réelle d'un capteur à un instant donné : deux scènes classées sous la même étiquette peuvent présenter des degrés de dégradation très différents. Les règles expertes raisonnent par capteur, là où l'*Attention Gating* raisonne par branche et peut donc privilégier une combinaison non anticipée. Enfin, le *Knowledge Based Gating* dépend d'une image caméra pour prédire la condition météorologique, ce qui le rend tributaire de la modalité la plus fragile précisément dans les situations où la sélection importe le plus.

CHAPITRE 9

Interface de visualisation et de démonstration

Les métriques agrégées du chapitre 8 quantifient la performance de PercepFlow, mais elles ne renseignent pas sur la manière dont le modèle parvient à ses décisions. Pour une architecture dont la contribution principale réside précisément dans un mécanisme de sélection, cette opacité constitue une limite pratique : elle complique le diagnostic des erreurs et rend l'architecture difficile à présenter à un interlocuteur non spécialiste.

Une interface web locale a donc été développée durant le stage afin de rendre le fonctionnement du modèle observable. Ce chapitre en présente les objectifs, l'architecture logicielle, l'organisation visuelle et les limites.

9.1 Objectifs de l'interface

L'interface répond à cinq besoins identifiés au cours du développement.

Faciliter la démonstration. Avant sa réalisation, présenter un résultat imposait de lancer plusieurs scripts successifs puis de consulter des fichiers de sortie séparés. L'interface regroupe sur une page unique les entrées des trois capteurs, les détections individuelles et le résultat fusionné.

Montrer l'intérêt de la fusion multimodale. En affichant côte à côte ce que détecte chaque capteur pris isolément et le résultat de la fusion, l'interface illustre concrètement la complémentarité des modalités, là où un tableau de métriques ne fait que la résumer.

Rendre la sélection dynamique observable. Le mécanisme d'*Attention Gating* attribue un score à chacune des sept branches et en retient trois. L'interface expose ces sept scores et met en évidence les branches sélectionnées, ce qui rend visible une décision autrement enfouie dans le réseau.

Aider au diagnostic. La juxtaposition des sorties permet de localiser l'origine d'une erreur : un capteur peu informatif, une branche produisant de mauvaises boîtes, une détection perdue lors de la fusion, une projection incohérente entre la vue de dessus et l'image caméra, ou une sélection de branches inadaptée à la scène.

Servir de support pédagogique. L'interface donne à voir le chemin complet allant des trois capteurs jusqu'à la décision finale, sans nécessiter la lecture du code.

9.2 Architecture logicielle

L'application suit une organisation en trois couches, représentée dans la figure 27. Le navigateur assure l'interaction avec l'utilisateur. Un serveur Flask reçoit les requêtes HTTP et expose l'API. Un service d'inférence charge et synchronise les données RADIATE, exécute le modèle, prépare les visualisations et renvoie les résultats au format JSON.




Figure 27. Architecture logicielle de l'interface PercepFlow.

La chaîne de perception exposée par l'interface reprend celle du modèle : extraction des caractéristiques des trois modalités, attribution d'un score aux sept branches, sélection des trois mieux notées, exécution des branches retenues, fusion des détections, puis projection du résultat sur l'image caméra pour l'affichage.

9.3 Synchronisation et déroulement d'une inférence

Les trois capteurs n'acquièrent pas leurs données au même rythme. L'interface reprend donc la stratégie décrite en section 4.3 et utilise la chronologie radar comme référence temporelle.

Lorsque l'utilisateur sélectionne un fichier, quel que soit le capteur dont il provient, l'application identifie la séquence et le type de capteur, retrouve l'instant correspondant,

recherche l'indice radar associé à partir des *timestamps* et des décalages du SDK RADIATE, puis charge les données des trois modalités. Ce point mérite d'être souligné : choisir un fichier issu d'un seul capteur ne signifie pas que le modèle n'utilise que ce capteur. Le fichier sert de point d'entrée pour retrouver la scène multimodale complète.

Pour chaque scène demandée, le service exécute successivement une inférence forcée sur la branche caméra seule, une sur la branche radar seule, une sur la branche LiDAR seule, puis l'inférence complète avec sélection dynamique. Les trois premières ne servent qu'à expliciter la contribution de chaque modalité dans l'affichage ; elles s'ajoutent à l'inférence principale et augmentent donc le temps de réponse du démonstrateur au-delà de la latence propre au modèle.

9.4 Organisation de la page et parcours utilisateur

L'en-tête rappelle le nom du modèle, l'architecture, le checkpoint chargé, la séquence courante et l'indice de la frame, ce qui permet de vérifier à tout instant la configuration utilisée. Le corps de la page s'organise ensuite en trois colonnes.

Zone	Contenu
Première colonne	Données des trois capteurs : image caméra, radar en vue de dessus et LiDAR en vue de dessus. Le radar bénéficie d'une égalisation d'histogramme et le LiDAR d'un rehaussement de contraste, uniquement à des fins de lisibilité.
Deuxième colonne	Sorties obtenues en forçant successivement la branche caméra seule, la branche radar seule et la branche LiDAR seule. La sortie caméra est projetée sur l'image native ; les sorties radar et LiDAR restent en vue de dessus, leur espace de détection naturel.
Troisième colonne	Résultat principal : détections des trois branches sélectionnées, fusionnées puis projetées sur l'image caméra, avec la classe prédite et le score de confiance de chaque boîte.
Panneau du <i>gate</i>	Liste des sept branches et de leur score, les trois branches retenues étant mises en évidence.
Panneau d'environnement	Condition générale, niveau de luminosité et appréciation de la visibilité, estimés par des règles simples sur l'image caméra.

Table 27. Organisation visuelle de l'interface.

Deux modes d'utilisation sont proposés. Le mode image unique, employé pour les captures de ce chapitre, permet d'examiner précisément une scène, de comparer les capteurs et de préparer une illustration. Le mode lecture parcourt les frames successives

d'une séquence enregistrée, avec des commandes de démarrage, de pause, d'arrêt, de déplacement du curseur et de réglage de la vitesse. Un navigateur de fichiers intégré, restreint à la racine RADIATE configurée, complète la boîte de dialogue native du système.




Figure 28. Interface sur la séquence `fog_8_1` : la caméra seule ne détecte pas le véhicule visible à gauche, le LiDAR ne renvoie que quelques points, mais le radar l'identifie et la fusion le restitue correctement.

La figure 28 constitue l'illustration la plus directe de l'apport de la fusion sélective. Sur cette scène de brouillard, le véhicule situé à gauche de la chaussée est parfaitement visible pour un observateur humain, mais la branche caméra seule ne produit aucune détection : le score qui lui est attribué par le *gate* tombe à 0,0004. Le nuage LiDAR se réduit à quelques points épars, la diffusion du faisceau par les gouttelettes en suspension privant cette modalité de l'essentiel de son information. Le radar, en revanche, identifie le véhicule avec une confiance de 0,94.

Le *gate* sélectionne en conséquence les branches `radar`, `camera_radar` et `all`, toutes trois faisant intervenir le radar, et la fusion restitue le véhicule sur l'image caméra avec un score de 0,86. Un objet invisible pour deux des trois modalités est donc récupéré par la troisième, sans qu'aucune règle météorologique n'ait été fournie au système. C'est exactement le comportement recherché.

Une limite observable. L'interface met également en évidence les cas où le système reste en défaut. La figure 29 présente une scène enneigée de la séquence `snow_1_0` où le radar détecte bien un véhicule, avec une confiance de 0,90, mais où cette détection

ne se retrouve pas dans la sortie fusionnée projetée sur l'image caméra.




Figure 29. Interface sur la séquence `snow_1_0` : une détection radar qui ne se retrouve pas dans la sortie fusionnée projetée.

Plusieurs causes peuvent expliquer ce comportement, et l'intérêt de l'interface est précisément de permettre de les distinguer. Il peut s'agir d'une détection écartée lors de l'agrégation par Soft-NMS, faute d'être confirmée par une seconde branche ; ou d'une projection de la vue de dessus vers l'image caméra devenue imprécise, l'objet étant éloigné. Ce type d'observation, impossible à obtenir depuis les seules métriques agrégées, oriente le diagnostic vers l'étage responsable.

9.5 Technologies employées

Couche	Technologies	Rôle
Interface	HTML, CSS, JavaScript	Mise en page, commandes, affichage dynamique
Serveur	Python, Flask	Routes web, API et orchestration
Documentation	Flasgger / Swagger	Exposition des routes HTTP
Modèle	PyTorch, Torchvision	Construction et exécution de PercepFlow
Traitement d'image	OpenCV, NumPy	Redimensionnement, rehaussement, dessin et encodage
Données	SDK RADIATE	Lecture, calibration et synchronisation
Communication	HTTP, JSON	Échanges entre navigateur et serveur
Accélération	CUDA si disponible, CPU sinon	Exécution du modèle

Table 28. Technologies mises en œuvre dans l'interface.

Deux choix de conception méritent d'être signalés. Le chargement du checkpoint est *paresseux* : la page affiche sa configuration sans charger immédiatement les poids, qui ne sont lus qu'à la première inférence puis conservés en mémoire. Par ailleurs, l'application web, le service d'inférence et le modèle sont nettement séparés, ce qui permet de faire évoluer la présentation sans réentraîner le modèle, ou le backend sans réécrire la page.

9.6 Portée et limites

L'interface constitue un **prototype fonctionnel de visualisation et d'explication**, et non une application industrielle déployée ni un système temps réel certifié. Plusieurs limites doivent être explicitées.

Ce n'est pas une acquisition temps réel. L'application lit des séquences RADIATE déjà enregistrées et avance frame par frame au moyen de requêtes successives. Elle ne reçoit aucun flux provenant de capteurs embarqués.

Ce n'est pas l'outil d'évaluation. Le seuil de 0,60 visible dans la page ne sert qu'à filtrer les boîtes affichées. Les métriques de mAP, de précision, de rappel et de F1 rapportées au chapitre 8 proviennent de scripts d'évaluation indépendants, appliqués à

une population et un protocole définis. Une visualisation convaincante ne constitue pas une preuve de performance statistique.

La projection vers la caméra a ses limites. PercepFlow détecte en vue de dessus ; les boîtes affichées sur l'image caméra résultent d'une projection s'appuyant sur la calibration et sur des hauteurs typiques par classe. Une boîte mal placée peut donc provenir de la synchronisation, de la calibration ou de la projection, et non du seul détecteur. L'imprécision est la plus marquée sur les petits objets et les classes rares.

Les indicateurs d'environnement sont heuristiques. La condition visuelle affichée est estimée par des règles simples fondées sur la luminosité moyenne et le contraste de l'image caméra. Elle ne provient pas du classifieur WeatherCNN présenté en section 7.5 et n'a pas été validée comme classification météorologique. Elle est par ailleurs indépendante du *gate*, qui décide à partir des seules caractéristiques extraites des trois modalités.

Toutes les informations calculées ne sont pas affichées. Le service produit davantage d'indicateurs que la page n'en montre, comme l'état heuristique de chaque capteur, la cohérence entre la fusion et les capteurs individuels, le nombre de détections au-dessus du seuil et leur confiance moyenne. Ces éléments pourront être exposés sans modifier le modèle de détection.

Prototype local. Le serveur écoute sur le port 5000 et autorise les requêtes croisées sans mécanisme d'authentification. Il doit rester cantonné à un environnement local ou contrôlé.

9.7 Perspectives d'évolution

Plusieurs extensions sont envisageables sans intervenir sur le modèle : afficher les indicateurs de supervision déjà calculés côté serveur, exposer des commandes de simulation de panne ou de bruit d'un capteur, mesurer la latence et le nombre d'images par seconde, permettre le réglage du seuil de confiance depuis la page, améliorer la projection des petits objets, et ajouter une authentification avant tout déploiement sur un réseau.

CHAPITRE 10

Discussion

Ce chapitre revient sur la portée des résultats obtenus, sur ce qu'ils permettent de conclure et sur ce qu'ils ne permettent pas d'affirmer.

10.1 Ce que les résultats établissent

La sélection apprise surpasse la sélection par règles. Le résultat le plus net de ce travail tient à la comparaison des deux stratégies. *PercepFlow* et le *Knowledge Based Gating* partagent les mêmes sept branches, le même bloc de fusion et le même ensemble de test ; l'écart observé est donc entièrement imputable au mécanisme de sélection. Les deux méthodes atteignent un rappel équivalent, mais la précision passe de 23,98 % à 57,80 %. La sélection par règles retrouve donc autant d'objets, au prix d'un volume de fausses détections bien supérieur.

L'explication tient à la nature de l'information exploitée. Une catégorie météorologique est un indicateur indirect de la fiabilité d'un capteur : deux scènes étiquetées « pluie » peuvent présenter des degrés de dégradation très différents. Les règles raisonnent en outre capteur par capteur, là où l'*Attention Gating* raisonne par branche et peut privilégier une combinaison non anticipée. Enfin, le *Knowledge Based Gating* dépend d'une image caméra pour prédire la condition, ce qui le rend tributaire de la modalité la plus fragile précisément dans les situations où la sélection importe le plus. Cette dernière limite est structurelle et ne se corrige pas par un réglage.

Le module de sélection retrouve seul la hiérarchie des capteurs. L'analyse des fréquences de sélection, en section 8.5, montre que la branche radar seule est absente en conditions claires puis apparaît selon un gradient croissant : 6 % sous la pluie, 8 % dans le brouillard, 10 % de nuit et 18 % sous la neige. Cet ordre reproduit celui de la dégradation de la caméra mesurée en section 6.1. Le module a donc reconstruit, à partir des seules caractéristiques extraites par les *stems*, la connaissance experte que le *Knowledge Based Gating* devait recevoir explicitement. Ce résultat valide l'hypothèse de départ selon laquelle le contexte peut être appris plutôt que fourni.

L'intégration géométrique de la caméra est le verrou déterminant. Sur les quatre approches évaluées en section 6.2, seule *Lift, Splat, Shoot* rend les branches impliquant la caméra géométriquement cohérentes avec les représentations radar et LiDAR. C'est cette brique qui permet à la caméra d'entrer dans le processus de sélection comme candidat à part entière, là où les travaux de référence la traitaient

en aval de la fusion. Le fait que les branches `camera_radar` et `all` figurent parmi les plus fréquemment retenues confirme que cette intégration apporte une information réellement exploitée par le modèle.

10.2 Limites

Les classes rares restent mal détectées. L'écart entre 52,96 % de précision moyenne sur les classes véhicules et 19,09 % sur les classes rares constitue la principale faiblesse du système. Trois causes se conjuguent : la sous-représentation de ces classes dans les annotations, leur faible emprise spatiale dans une représentation en vue de dessus, et leur visibilité réduite en conditions dégradées. Ce résultat reflète autant les limites de l'architecture que la composition du jeu de données, mais il reste pénalisant : piétons et cyclistes sont les usagers les plus vulnérables, et ce sont ceux que le système détecte le moins bien.

Le budget d'entraînement contraint les conclusions. Les moyens de calcul décrits en section 7.1 ont limité le nombre d'*epochs*, en particulier pour le module de projection de la caméra dont la distribution de profondeur est apprise. Les performances rapportées constituent donc une borne inférieure de ce que l'architecture peut atteindre, et non son plafond. Cette contrainte a également conduit à écarter les architectures à base de Transformers, dont l'apport n'a pas pu être évalué.

L'ablation est incomplète. L'étude conduite en section 8.2 montre une progression monotone des performances jusqu'à $k = 3$, sans saturation observable. Aucune valeur supérieure n'ayant été testée, il n'est pas possible d'affirmer que $k = 3$ constitue un optimum. Ce point mérite d'être souligné car il diffère du comportement rapporté par HydraFusion, où l'activation de branches supplémentaires dégradait les résultats au-delà de trois.

Un ensemble de test déséquilibré. Comme l'indique l'annexe C, 13 des 22 séquences de test correspondent à des conditions claires. Les métriques globales reflètent donc majoritairement le comportement du système en conditions favorables, alors même que la contribution porte sur la robustesse aux conditions dégradées. Les analyses par condition et les fréquences de sélection compensent partiellement ce biais, mais une évaluation dédiée aux seules séquences dégradées serait plus représentative.

10.3 Portée des résultats

Les performances rapportées ne sont pas directement comparables à celles de la littérature. HydraFusion annonce une mAP de 81,31 % sur RADIATE, mais avec une

répartition, un ensemble de classes, un protocole d'évaluation et un budget d'entraînement différents. Une comparaison chiffrée entre les deux travaux n'aurait donc pas de sens. Ce qui est comparable, en revanche, ce sont les tendances : la supériorité de la sélection apprise sur la sélection par règles, et l'intérêt d'activer un sous-ensemble de branches plutôt que la totalité, se retrouvent dans les deux cas.

Il convient enfin de rappeler que l'évaluation porte sur un unique jeu de données, acquis avec une plateforme de capteurs donnée dans une région géographique donnée. La généralisation à d'autres configurations matérielles ou à d'autres environnements de conduite reste à établir.

CHAPITRE 11

Conclusion et perspectives

Ce travail a porté sur la fusion multimodale adaptative pour la perception en conduite autonome. Deux architectures de fusion sélective ont été développées successivement. La première, le *Knowledge Based Gating*, sélectionne les capteurs privilégiés au moyen de règles expertes déclenchées par la condition météorologique prédite par un classifieur WeatherCNN. Les limites de cette sélection à règles fixes ont ensuite motivé la conception de **PercepFlow**, dont le mécanisme d'*Attention Gating* active dynamiquement les combinaisons les plus pertinentes parmi les modalités radar, LiDAR et caméra, à partir des seules caractéristiques extraites par le réseau.

Bilan quantitatif. PercepFlow atteint une mAP de 36,02 % et un F1 de 60,3 % sur environ 40 % des 60 séquences totales de RADIATE. Les performances sont particulièrement élevées sur les classes véhicules (mAP 52,96 %), tandis que les classes rares restent limitées (mAP 19,09 %), en cohérence avec le déséquilibre des annotations. WeatherCNN atteint une exactitude de 97,0 % et un F1 macro de 97,0 %, confirmant sa fiabilité pour le *Knowledge Based Gating*. Ce dernier plafonne néanmoins à une mAP de 29,01 % et à un F1 de 34,91 %, pénalisé par une précision de 23,98 %. Une prédiction météorologique fiable ne suffit donc pas à garantir une sélection de branches pertinente.

Perspectives. Les perspectives principales concernent quatre axes. Le premier est l'amélioration de l'intégration géométrique de la caméra dans l'espace BEV via LSS avec davantage d'epochs d'entraînement. Le deuxième est l'amélioration de la détection des classes rares par des stratégies d'équilibrage et de sur-représentation des données. Le troisième est la combinaison du contexte météorologique du *Knowledge Based Gating* avec la sélection apprise de PercepFlow. Le quatrième est d'approfondir l'analyse de l'impact du nombre de branches sélectionnées k , notamment en étudiant plus finement les compromis entre performance, robustesse et coût de calcul.

ANNEXE A

Capteurs de la plateforme RADIATE

Le tableau 29 récapitule les capteurs embarqués sur le véhicule d'acquisition RADIATE et la représentation effectivement exploitée pour chacun dans ce travail.

Modalité	Modèle	Représentation exploitée
Radar	Navtech CTS350-X	Image cartésienne 1152×1152 px, vue de dessus native, environ 4 Hz, champ de vision de 360° en azimuth
LiDAR	Velodyne HDL-32E	Nuage de points 32 canaux au format CSV, projeté en image de vue de dessus
Caméra	Caméra stéréo ZED	Image en perspective frontale, projetée en vue de dessus par <i>Lift</i> , <i>Splat</i> , <i>Shoot</i> ; flux <code>zed_left</code> et <code>camera_right_rect</code>

Table 29. Capteurs de la plateforme RADIATE et représentation retenue.

ANNEXE B

Dimensions des représentations dans PercepFlow

Le tableau 30 récapitule la forme des tenseurs aux étapes clés du pipeline. B désigne la taille du lot, H et W les dimensions spatiales d'entrée.

Étape	Forme du tenseur	Module
Entrée radar (vue de dessus cartésienne)	1152×1152	Navtech
Sortie RadarStem	$[B, 64, H/4, W/4]$	ResNet-18 tronqué
Sortie LidarStem	$[B, 64, H/4, W/4]$	ResNet-18 tronqué
Sortie CameraStem	$[B, 64, H/4, W/4]$	ResNet-18 tronqué
Frustum 3D (étape <i>Lift</i>)	$[B, 64, D, H', W']$, $D = 24$	LSS
Carte BEV caméra (étape <i>Splat</i>)	$[B, 64, 128, 128]$	LSS
Concaténation des <i>stems</i>	$[B, 192, H/4, W/4]$	Entrée du <i>gating</i>
Scores de branches	$[B, 7]$	<i>Attention Gating</i>

Table 30. Formes des tenseurs le long du pipeline PercepFlow.

Les 24 intervalles de profondeur de l'étape *Lift* sont répartis de manière logarithmique entre 2 et 52 mètres. La sortie de l'étape *Splat* partage exactement la forme des sorties des *stems* radar et LiDAR, ce qui rend la caméra directement fusionnable dans toutes les branches multimodales.

ANNEXE C

Composition de l'ensemble de test

L'évaluation finale de PercepFlow porte sur 22 des 60 séquences de RADIATE, représentant 11 338 images annotées. Le tableau 31 donne la liste nominative de ces séquences et leur condition d'acquisition.

Condition	Séquences	Noms des séquences
Conditions claires	13	city_1_1, city_3_0, city_3_7, city_7_0, motorway_2_2, junction_1_8, junction_1_9, junction_1_10, junction_1_11, junction_1_12, junction_1_13, junction_2_6, junction_3_2
Nuit	4	night_1_0, night_1_2, night_1_4, night_1_5
Brouillard	2	fog_6_0, fog_8_1
Pluie	2	rain_3_0, rain_4_0
Neige	1	snow_1_0
Total	22	11 338 images annotées

Table 31. Séquences RADIATE composant l'ensemble de test, par condition d'acquisition.

Les conditions dégradées représentent 9 des 22 séquences de test. Cette répartition, déséquilibrée en faveur des conditions claires, doit être prise en compte dans l'interprétation des performances globales : les métriques agrégées reflètent majoritairement le comportement du système en conditions favorables.

Références

- [1] DriveSense : Système de perception avancé pour la conduite autonome. Technical report, Audensiel Innovation, 2024.
- [2] Nadeen Abu-Alrub and Nathir A. Rawashdeh. Compact CNN-based road weather condition detection by grayscale image band for ADAS. In *SPIE Autonomous Systems : Sensors, Processing and Security*, 2022.
- [3] Navaneeth Bodla, Bharat Singh, Rama Chellappa, and Larry S. Davis. Soft-NMS : Improving object detection with one line of code. In *IEEE International Conference on Computer Vision*, 2017.
- [4] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *European Conference on Computer Vision*, 2020.
- [5] Shao-Yu Chu and Ming-Sui Lee. MT-DETR : Robust end-to-end multimodal detection with confidence fusion. In *IEEE/CVF Winter Conference on Applications of Computer Vision*, 2023.
- [6] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2005.
- [7] Yinpeng Dong, Caixin Kang, Jinlai Zhang, Zijian Zhu, Yikai Wang, Xiao Yang, Hang Su, Xingxing Wei, and Jun Zhu. Benchmarking robustness of 3D object detection to common corruptions in autonomous driving. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.
- [8] Pedro F. Felzenszwalb, Ross B. Girshick, David McAllester, and Deva Ramanan. Object detection with discriminatively trained part-based models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32(9) :1627–1645, 2010.
- [9] Ross Girshick. Fast R-CNN. In *IEEE International Conference on Computer Vision*, 2015.
- [10] Ross Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2014.
- [11] Xiaoshuai Hao, Guanqun Liu, Yuting Zhao, Yuheng Ji, Mengchuan Wei, Haimei Zhao, Lingdong Kong, Rong Yin, and Yu Liu. MSC-Bench : Benchmarking and analyzing multi-sensor corruption for driving perception. *arXiv preprint arXiv :2501.01037*, 2025.

- [12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition. In *European Conference on Computer Vision*, 2014.
- [13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [14] Haowen Lai, Peng Yin, and Sebastian Scherer. AdaFusion : Visual-LiDAR fusion with adaptive weights for place recognition. *IEEE Robotics and Automation Letters*, 7(4) :12038–12045, 2022.
- [15] Zhiqi Li, Wenhai Wang, Hongyang Li, Enze Xie, Chonghao Sima, Tong Lu, Yu Qiao, and Jifeng Dai. BEVFormer : Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers. In *European Conference on Computer Vision*, 2022.
- [16] Arnav Vaibhav Malawade, Trier Mortlock, and Mohammad Abdullah Al Faruque. EcoFusion : Energy-aware adaptive sensor fusion for efficient autonomous vehicle perception. In *ACM/IEEE Design Automation Conference*, 2022.
- [17] Arnav Vaibhav Malawade, Trier Mortlock, and Mohammad Abdullah Al Faruque. HydraFusion : Context-aware selective sensor fusion for robust and efficient autonomous vehicle perception. In *ACM/IEEE International Conference on Cyber-Physical Systems*, 2022.
- [18] Dong-Hee Paek and Seung-Hyun Kong. Availability-aware sensor fusion via unified canonical space. *arXiv preprint arXiv :2503.07029*, 2025.
- [19] Jonah Philion and Sanja Fidler. Lift, splat, shoot : Encoding images from arbitrary camera rigs by implicitly unprojecting to 3D. *arXiv preprint arXiv :2008.05711*, 2020.
- [20] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN : Towards real-time object detection with region proposal networks. In *Advances in Neural Information Processing Systems*, 2015.
- [21] Marcel Sheeny, Emanuele De Pellegrin, Saptarshi Mukherjee, Amir Ahrabian, Sen Wang, and Andrew Wallace. RADIATE : A radar dataset for automotive perception in bad weather. In *IEEE International Conference on Robotics and Automation*, 2021.
- [22] Roman Solovyev, Weimin Wang, and Tatiana Gabruseva. Weighted boxes fusion : Ensembling boxes from different object detection models. *Image and Vision Computing*, 107, 2021.
- [23] Jasper R. R. Uijlings, Koen E. A. van de Sande, Theo Gevers, and Arnold W. M. Smeulders. Selective search for object recognition. *International Journal of Computer Vision*, 104(2) :154–171, 2013.

- [24] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.
- [25] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2001.